

Índice general

1. Introducción	1
1.1. Contexto del proyecto	1
1.2. Antecedentes: Ingeniería Dirigida por Modelos y Desarrollo Dirigido por modelos	3
1.3. Motivación y Objetivos	8
1.4. Estructura del Documento	9
2. Antecedentes y Planificación	11
2.1. Caso de estudio: Generador de código CQL-Cassandra	11
2.2. EMF	12
2.3. Epsilon	13
2.3.1. Epsilon Object Language	14
2.3.2. Epsilon Transformation Language	15
2.3.3. Epsilon Generation Language	15
2.4. Cassandra	16
2.5. Planificación	20
2.6. Sumario	21
3. Transformación modelo a modelo	23
3.1. Introducción	23
3.2. Metamodelo Cassandra	24
3.3. Transformación de Modelo UML a Cassandra	26
3.3.1. Transformación del modelo	26
3.3.2. Transformación de clases	27
3.3.3. Transformación de atributos	27
3.3.4. Transformación de asociaciones	29
3.3.5. Transformación de tipos primitivos	29
3.4. Caso de estudio transformación modelo a modelo	30
3.5. Sumario	31
4. Transformación modelo a texto	33
4.1. Introducción	33
4.2. Generador de código	34

4.3. Caso de estudio Twissandra	36
4.4. Pruebas	37
4.5. Sumario	37
5. Sumario y Trabajos Futuros	39
5.1. Sumario	39
5.2. Experiencia personal	40
5.3. Trabajos futuros	41

Índice de figuras

1.1. Capas del modelado de lenguajes	4
1.2. (a) Meta-modelo, (b) Sintaxis concreta, (c) Sintaxis grafica	5
1.3. Proceso de transformación de un modelo	6
1.4. Meta-modelo del grafo	7
1.5. Meta-modelo de la red	7
1.6. Resultado transformación HTML	8
2.1. Modelo UML Twissandra	12
2.2. Ejemplo metamodelo casa	14
2.3. Ejemplo código EOL	15
2.4. Ejemplo código ETL	16
2.5. Ejemplo código EGL	17
2.6. Estructura column family	19
2.7. Ejemplo código CQL	20
3.1. Metamodelo Cassandra	25
3.2. Regla de transformación XX	28
4.1. Regla de transformación Primary Key	35
4.2. Modelo UML Twissandra	36
4.3. Código resultante Twissandra	38

Índice de cuadros

2.1. Ejemplo estructura columna	19
3.1. Equivalencias tipos primitivos UML-Cassandra	30

Capítulo 1

Introducción

Este capítulo sirve de introducción a la presente Memoria de Proyecto de Fin de Carrera. En primer lugar se realiza una breve introducción de los conceptos generales del proyecto. La siguiente sección describe conceptos orientados a la Ingeniería de Lenguajes Dirigida por Modelos y al Desarrollo Dirigido por Modelos, términos clave para entender el contexto del proyecto. La tercera sección describe las motivaciones y objetivos. La última sección está dedicada a describir la estructura del documento.

Índice

1.1. Contexto del proyecto	1
1.2. Antecedentes: Ingeniería Dirigida por Modelos y Desarrollo Dirigido por modelos	3
1.3. Motivación y Objetivos	8
1.4. Estructura del Documento	9

1.1. Contexto del proyecto

El término conocido como modelado ha sido asociado a las bases de datos y a la gestión de datos durante décadas. [1] El modelo entidad-relación (ER) y el conjunto de reglas para la transformación de un modelo ER en un esquema relacional es un ejemplo bien conocido y utilizado. Recientemente las nuevas tecnologías de gestión de bases datos, también conocidas como tecnologías NoSQL, han surgido como respuesta a los nuevos retos y demandas de las aplicaciones de internet modernas. Estas tecnologías se han centrado en el nivel de aplicación, al carecer de un soporte de modelado adecuado. Algunas de las aplicaciones de internet de uso extendido y masificado, como las redes sociales (por ejemplo, Twitter) o tiendas online (por ejemplo, Amazon), están generando nuevos desafíos en materia de almacenamiento y gestión de datos. Por ejemplo, la disponibilidad se está convirtiendo en un aspecto crítico en estos sistemas, ya que una caída del sistema puede generar

pérdidas multimillonarias a estas empresas. Además, estas aplicaciones tienen que mantener su funcionalidad ante las peticiones de una gran cantidad de usuarios, en los que estos usuarios ejecutan operaciones muy similares (por ejemplo, publicar un mensaje en una red social después de un evento popular, como la final de la Super Bowl o unas elecciones a la presidencia).

En este contexto las bases de datos relacionales han resultado ser insuficientes de cara a satisfacer estas nuevas exigencias. Las tecnologías NoSQL (Not Only SQL) [2] tienen como objetivo hacer frente a estas nuevas exigencias. NoSQL sacrifica algunas de las ventajas bien conocidas de los sistemas de gestión de bases de datos relacionales, como la integridad o la manipulación de transacciones, con el fin de proporcionar una mejor escalabilidad y un mayor rendimiento. Siguiendo esta idea, varios sistemas NoSQL, como Cassandra [3], HBase [4] o MongoDB [5], han aparecido en los últimos años.

Sin embargo, las tecnologías NoSQL no están aún integradas en los procesos de desarrollo software, su integración puede ayudar a los ingenieros software en la construcción de repositorios NoSQL desde las primeras etapas del ciclo de vida del software hasta la finalización del producto. El modelado de datos de un sistema NoSQL como Cassandra dista del modelado de las bases de datos relacionales. Cassandra por ejemplo, utiliza como unidad básica las *columns* cuyo equivalente sería el campo en el modelo relacional o como unidad de almacenamiento de estas *columns* utiliza las *column families* como tablas etc.. Este trabajo tiene como objetivo contribuir con una herramienta para superar esta barrera, proporcionando un generador de código que genera repositorios de datos NoSQL.

Por lo tanto, este trabajo se centrará en la creación de un generador de código que transforma un modelo de datos desarrollado en UML, en código para la creación de un repositorio de datos NoSQL. Para este trabajo, nos centraremos en los sistemas orientados a columnas. Las razones son las siguientes: (1) los sistemas orientados a columnas son sistemas de propósito general, mientras que otros sistemas NoSQL, tales como, las bases de datos documentales que como su propio nombre indica están orientadas a la gestión de documentos, este tipo de bases de datos son más específicos a ese dominio; (2) los estudios cursados en Ingeniería Informática nos han proporcionado experiencia previa en el manejo de estos sistemas. Más concretamente, hemos decidido utilizar Cassandra [3] como sistema NoSQL orientado a columnas debido a su creciente popularidad. Se ha decidido que el lenguaje de modelado utilizado en este proyecto de fin de carrera sea UML por varias razones: (1) es un estándar de la OMG (Object Management Group), (2) es un lenguaje de modelado conocido y utilizado durante la carrera; y, (3) UML tiene un gran número de herramientas que dan soporte de cara al desarrollo.

Para realizar este generador de código se utilizan una serie de técnicas de transformación entre modelos conocidas como "Desarrollo Dirigido por Modelos" (MDD). MDD se puede definir como un enfoque de la Ingeniería del

software y de la Ingeniería dirigida por modelos (MDE) que utiliza el modelo para crear un producto. ¿Y que es un modelo?. Un modelo se puede entender como la descripción o representación de un sistema en un lenguaje bien definido. Para entender lo que representa un modelo dentro de MDE hay que saber previamente lo que es un meta-modelo. Un meta-modelo es un modelo usado para especificar un lenguaje, básicamente describe las características del lenguaje. Por lo tanto un modelo se puede entender como la instancia de un meta-modelo. Estos conceptos son ampliados en siguientes secciones.

El resultado de la utilización del desarrollo dirigido por modelos es traducido en reducción de costes debido a que el recurso humano requerido es menor, un aumento de la productividad y reutilización de componentes, además se puede aumentar el nivel de abstracción a la hora de realizar el diseño de un software.

En resumen la utilización de modelos UML respecto a modelos especificados en Cassandra a la hora de crear una base de datos no relacional proporciona una abstracción para aquellos desarrolladores que no estén muy familiarizados con el modelado de bases de datos no relacionales. La utilización de modelos diseñados en UML proporciona las siguientes ventajas: (1) UML es un lenguaje de modelado bien conocido por toda la comunidad. (2) La automatización de estos procesos nos permite crear software más rápido, más fiable y de mayor calidad lo que nos lleva a mantener buenas prácticas. En definitiva este trabajo pretende contribuir a satisfacer las carencias y virtudes citadas, proporcionando una herramienta que bajo las bases de un proceso de transformación dirigido por modelos, transforma modelos UML y genera key spaces para sistemas NoSQL orientado a columnas. Esperamos que esto permita a los equipos de desarrollo ahorrar esfuerzos y, por lo tanto, reducir costes.

En las siguientes secciones se desarrollan los siguientes apartados: El apartado 1.2 expande información sobre la Ingeniería dirigida por modelos y el Desarrollo Dirigido por Modelos. El apartado 1.3 presenta la motivación y objetivos del proyecto. Finalmente el apartado 1.4 describe la estructura que tendrá el documento presente.

1.2. Antecedentes: Ingeniería Dirigida por Modelos y Desarrollo Dirigido por modelos

Según [6] la Ingeniería Dirigida por Modelos (MDE) puede ser definida como la *"técnica que hace uso, de forma sistemática y reiterada, de modelos como elementos primordiales a largo de todo el proceso de desarrollo. MDE trabaja con modelos como entradas al proceso y produce modelos como salidas del mismo"*. El concepto de Desarrollo Dirigido por Modelos (MDD) es como se puede observar en la Figura 1.1, un subconjunto de la Ingeniería Dirigida por Modelos (MDE). A diferencia de MDD,[7] MDE va más allá de las




Figura 1.1: Capas del modelado de lenguajes

actividades de desarrollo puros y abarca otras tareas basadas en el proceso de modelado por ejemplo, aplicar ingeniería inversa a un modelo.

Tanto MDD como MDE aportan varias ventajas respecto a métodos de desarrollo tradicionales, podemos encontrar las siguientes ventajas [8], [9]:

1. Tiempo de desarrollo menor.
2. Reutilización de componentes en distintos sistemas.
3. Alto nivel de abstracción para escribir aplicaciones a través de la arquitectura de niveles del meta-modelado y las capas de modelado de MDD. Este beneficio favorece diseñar una aplicación partiendo de lo mas general a lo más concreto, es decir, son independientes de la tecnología.
4. Un menor número de líneas de código escritas, ya que los niveles de abstracción que aporta MDD a través de los modelos y meta-modelos diseñados fomentan el reúso del código y de los modelos.
5. Si se centran los esfuerzos en el generador de código se puede mejorar la calidad del software, además reducimos la cantidad de errores así como el tiempo dedicado en pruebas e incurrimos en buenas prácticas de desarrollo.

Una vez entendidos los conceptos anteriores y los beneficios que nos proporciona este enfoque de desarrollo se presentan los conceptos básicos que nos ayudaran a comprender como funciona MDD.

El enfoque MDD parte del meta-modelo [10], un meta-modelo es la representación del lenguaje que se desea implementar definido en sintaxis abstracta. Un lenguaje de modelado está formado de sintaxis y semántica. La sintaxis se puede entender como el conjunto de normas o reglas de escritura

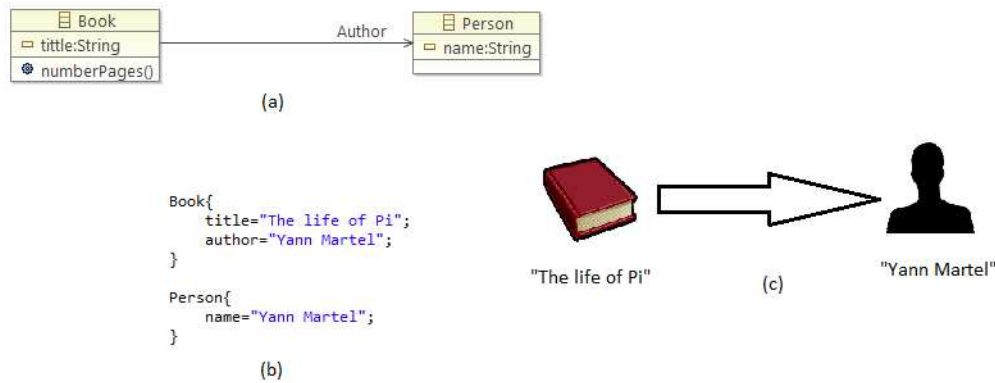


Figura 1.2: (a) Meta-modelo, (b) Sintaxis concreta, (c) Sintaxis grafica

que ha de tener el lenguaje. La semántica refleja el significado de la sintaxis. La definición de esta sintaxis abstracta forma parte del primer paso en el proceso de diseño de un lenguaje, esta sintaxis abstracta especifica la forma del meta-modelo. Clases y relaciones de dominio son los principales elementos que forman parte de un meta-modelo. A su vez los meta-modelos son considerados instancias de estos lenguajes de modelado. Un ejemplo de meta-modelo es la definición de UML [11]. En UML por ejemplo elementos como las clases, paquetes o atributos se pueden usar dentro de UML.

El siguiente paso consiste en la definición de la sintaxis concreta, este paso se basa en la representación de los elementos bien definidos en la sintaxis abstracta, esto es la creación de un modelo. Un modelo es la representación concreta de los elementos descritos en la sintaxis abstracta o meta-modelo. Por lo tanto un modelo siempre posee las propiedades y cumple las restricciones de su meta-modelo. En la figura 1.2 se pueden observar representaciones de los elementos descritos.

Según [10], formalizando los conceptos anteriores estos son los pasos que hay que realizar para la creación de un nuevo lenguaje de modelado, esto nos servirá para establecer las bases que ha de tener el lenguaje de modelado de Cassandra:

1. En primer lugar hay que establecer cuál va a ser la sintaxis de nuestro lenguaje de modelado. Para ello hay que crear un meta-modelo. El meta-modelo ha de ser construido utilizando un lenguaje de meta-modelado, el lenguaje de modelado utilizado en el presente proyecto es ECore [8]. Además de ECore hay otros lenguajes de modelado como puede ser MOF [9].
2. El siguiente paso consiste en la definición de la sintaxis concreta de nuestro lenguaje de modelado. La creación de un modelo bien definido a partir del meta-modelo creado en el paso anterior.




Figura 1.3: Proceso de transformación de un modelo

3. La definición de la semántica del lenguaje de modelado es el último paso, por ejemplo crear un generador que transforme los elementos del modelo en elementos de un lenguaje distinto bien definido.

La herramienta utilizada para crear el lenguaje de modelado correspondiente a Cassandra es EMF, un plugin de eclipse que nos permite crear y trabajar con lenguajes de modelado. MDD proporciona las transformaciones de modelos como principal herramienta para trabajar con modelos en el proceso de desarrollo software. Existen dos tipos de transformaciones:

1. *Model to model (M2M)*. Dado un modelo de entrada esta transformación produce otro modelo como salida. Este tipo de transformación se puede utilizar de varias formas, la primera transformar un modelo dándole propiedades que no posee el original. La segunda es la que se utilizara en el presente proyecto, dado un modelo origen definido en UML realizar una transformación a un modelo destino definido en Cassandra (Figura 1.3).
2. *Model to text (M2T)*. Es la ultima transformación que se realiza en la etapa de desarrollo para la creación del generador de código de la aplicación. Estas transformaciones no generan un modelo de salida sino una representación textual del modelo que se desea transformar. Se puede utilizar para generar por ejemplo una representación del modelo transformado en formato HTML.

Para explicar todo este proceso se presenta un sencillo ejemplo donde se explican cómo se utilizan las técnicas de desarrollo dirigido por modelos, Model to Model (M2M) y Model to Text (M2T). Para aplicar M2M nos harán falta dos meta-modelos (uno origen y uno destino) y para aplicar M2T se ha diseñado un sencillo generador de código HTML.




Figura 1.4: Meta-modelo del grafo

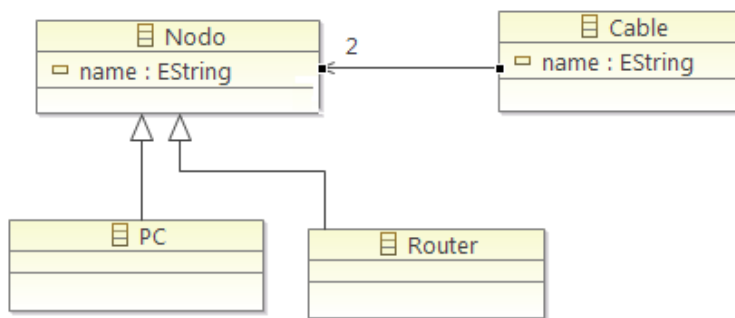


Figura 1.5: Meta-modelo de la red

La figura 1.4 muestra la representación de la sintaxis abstracta o meta-modelo del lenguaje. El meta-modelo consiste en un sencillo grafo el cual está compuesto de un número indefinido de nodos, estos nodos están conectados entre sí mediante aristas. Estos nodos como se ve en la imagen tienen un atributo de tipo "Tcolor" por lo que un Nodo puede ser de color rojo o de color azul. Por lo tanto un modelo bien definido de este meta-modelo será un modelo que contenga un grafo con un número cualquiera de Nodos conectados dos a dos entre sí mediante aristas.

A continuación se presenta otro meta-modelo como se ve en la figura 1.5. Este meta-modelo consiste en la representación de una red de computadores que está compuesta de PC's y Routers estos análogamente al anterior meta-modelo están conectados indistintamente entre sí mediante cables. Tanto los nodos como los cables tienen un atributo de tipo "String" para definir el nombre.

Nuestro objetivo es la transformación de un modelo de tipo Grafo a un modelo de tipo Red, dependiendo del color del Nodo, el Nodo será transfor-

Conexiones

A1	PC1	Router1
A2	PC2	PC3
A3	Router2	PC4

Figura 1.6: Resultado transformación HTML

mado en un PC o en un Router (Rojo-PC, Azul-Router) para realizar esta transformación se utilizan técnicas M2M. Una vez definido el modelo de tipo Red deseamos crear una representación textual del modelo generado, para ello utilizamos técnicas M2T. En este caso la representación del modelo es realizada en formato HTML. La representación del código generado utilizando un modelo de tipo grafo y aplicando la transformación entre modelos es el que se puede observar en la figura 1.6.

El proceso que se ha seguido es explicado más detalladamente en capítulos posteriores con un caso de estudio analizado, tanto las técnicas de transformación de modelos como la realización del generador de código así como la creación de los modelos.

1.3. Motivación y Objetivos

Como hemos visto a lo largo de la introducción el enfoque que proporciona el Desarrollo Dirigido por Modelos así como la Ingeniería Dirigida por Modelos nos proporciona múltiples ventajas respecto al desarrollo tradicional por lo que la utilización de este enfoque es apropiada para la realización del generador de código así como para la transformación entre modelos, además la utilización de tecnologías NoSQL frente a tecnologías de gestión de bases de datos tradicionales en terrenos donde es de extrema importancia aspectos como la disponibilidad o el manejo de cantidades de datos descomunales garantizan que NoSQL es una apuesta de futuro segura.

El objetivo de este proyecto de fin de carrera es la implementación de un generador de código que transforme modelos especificados en UML 2.0 en su correspondiente código de creación de bases de datos en Cassandra. Para ello, previa implementación del generador de código habrá que transformar el modelo UML a un modelo escrito en Cassandra, para lograr este objetivo será necesario definir una serie de reglas de equivalencias entre modelos utilizando para ello el lenguaje Epsilon Transformation Language (ETL). Por lo tanto necesitaremos desarrollar un meta-modelo que describa el modelado de Cassandra y un meta-modelo que describa el modelado de UML (este último meta-modelo lo proporciona la herramienta con la que vamos a tra-

bajar). La construcción del meta-modelo se realizara utilizando el lenguaje para la definición de lenguajes de modelado Eclipse Modelling Framework (EMF). Dicho generador y dicha transformación se desarrollaran utilizando el enfoque y las técnicas que proporcionan el Desarrollo Dirigido por Modelos, para la creación de este generador de código utilizaremos el lenguaje Epsilon Generation Language (EGL). Por lo tanto utilizaremos la suite de lenguajes que proporciona Epsilon para el desarrollo de software dirigido por modelos.

Como resultado del proyecto se genera un código para la creación de una base de datos en Cassandra escrito en el lenguaje de consultas de Cassandra, Cassandra Query Language (CQL) que puede ser ejecutado en cualquier herramienta que soporte dicho lenguaje.

1.4. Estructura del Documento

Tras este capítulo de introducción, la presente memoria del Proyecto Fin de Carrera se estructura tal y como se describe a continuación: El Capítulo 2 describe en términos generales todos los conceptos y tecnologías que son necesarios para comprender el contenido de esta memoria conceptos tales como Cassandra o EMF por ejemplo. El Capítulo 3 describe el proceso de desarrollo y creación de las reglas para realizar la transformación entre modelos. El Capítulo 4 explica como se ha realizado el generador de código así como las técnicas y tecnologías utilizadas. Finalmente el Capítulo 5 presenta mis conclusiones tras la realización del proyecto así como posibles mejoras de la herramienta, todo como cierre de la memoria del proyecto de fin de carrera.

Capítulo 2

Antecedentes y Planificación

Este capítulo describe las tecnologías y técnicas utilizadas en el desarrollo del presente Proyecto de Fin de Carrera. La primera sección está dedicada a introducir el caso de estudio que se analizará a lo largo del presente proyecto. La siguiente sección está dedicada a describir en qué consiste Eclipse Modeling Framework (EMF) la herramienta utilizada para desarrollar lenguajes de modelado. A continuación se describe la herramienta Epsilon, herramienta que se ha utilizado para desarrollar el generador de código. La siguiente sección está dedicada a explicar de manera breve algunos conceptos de Cassandra. Finalmente se expone la planificación que ha seguido el proyecto para su realización, desde formación hasta etapas de desarrollo.

Índice

2.1. Caso de estudio: Generador de código CQL-Cassandra	11
2.2. EMF	12
2.3. Epsilon	13
2.4. Cassandra	16
2.5. Planificación	20
2.6. Sumario	21

2.1. Caso de estudio: Generador de código CQL-Cassandra

En esta sección se presenta el caso de estudio que se analizará lo largo de este proyecto. El caso de estudio trata sobre Twissandra, Twissandra es un proyecto creado para aprender como utilizar Cassandra. El modelo UML correspondiente a Twissandra se puede ver en la figura 2.1. Twissandra es una versión simplificada de Twitter, que es a menudo utilizada para demostrar las capacidades de Cassandra. Twitter es una red social de microblogging que actualmente está muy extendida, Twitter permite escribir a los usuarios

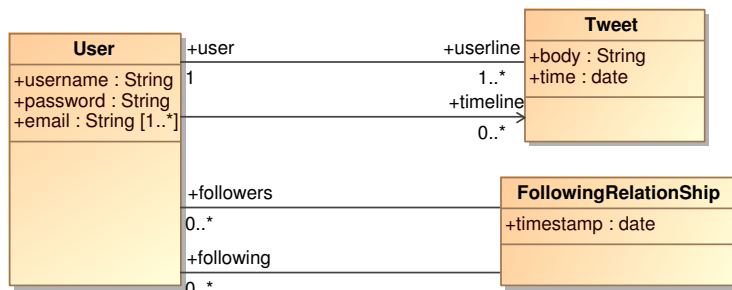


Figura 2.1: Modelo UML Twissandra

pequeños mensajes de texto, los usuarios registrados pueden publicar tweets. Un tweet es simplemente un texto con un límite de 140 caracteres publicado a una hora determinada. La colección de todos los tweets publicados por un usuario cronológicamente ordenados, están asignados a su Userline. Cada usuario registrado en Twitter puede seguir a otros usuarios registrados. Cuando decimos que Pedro sigue a María significa que Pedro está interesado en saber qué publica María en su tablón, por lo que Pedro recibirá todos los mensajes que publique María en su tablón. Así, cada usuario registrado tiene también un timeline que vendría a ser la colección de todos los tweets de las personas a las que sigue ordenadas cronológicamente.

Los principales casos de uso de un sistema de este tipo son: (1) obtener el timeline de un usuario determinado; (2) obtener el Userline de un usuario, (3) obtener la lista de usuarios que un usuario está siguiendo; y (4) obtener la lista de usuarios que están siguiendo a un usuario específico. Estas dos últimas listas deben ser ordenadas cronológicamente.

Como vemos Twissandra es una versión simplificada de Twitter sin embargo se considera un buen ejemplo a analizar ya que Twitter goza de gran popularidad y es una de las redes sociales más usadas del mundo. Una vez entendido esto en los siguientes capítulos se procede a detallar el proceso de creación de un repositorio de datos en Cassandra que cubra los casos de usos citados anteriormente describiendo los procesos de transformación entre modelos que se realizaran así como la generación de código del repositorio de datos en Twissandra.

2.2. EMF

Para comenzar el desarrollo del proyecto bajo el paradigma del desarrollo software dirigido por modelos necesitamos definir que lenguajes de modelado vamos a utilizar. En el capítulo anterior comentábamos que es necesario definir el lenguaje de modelado que utilizara Cassandra para ello usaremos EMF. Eclipse Modeling Framework (EMF) [2.2] es un framework

de modelado que nos proporciona la base para la elaboración de lenguajes de modelado. Para la creación de meta-modelos EMF [2.3] utiliza dos modelos de meta-datos: Ecore y Genmodel. Ecore contiene la información sobre las clases que se han definido. Genmodel contiene información adicional para la generación del código, por ejemplo la ruta y la información del archivo. Genmodel también contiene atributos que sirven de control a la hora de generar el código, encontramos los siguientes parámetros de control:

1. EClass: representa una clase, con cero o más atributos y cero o más referencias.
2. EAttribute: representa un atributo que tiene un nombre y un tipo.
3. EReference: representa un extremo de una asociación entre dos clases.
4. EDataType: representa el tipo de un atributo, por ejemplo, int, float.

Estos atributos nos servirán a la hora de crear las reglas de transformación entre modelos UML y modelos Cassandra.

Utilizando EMF se pueden crear meta-modelos de forma gráfica muy similar a los diagramas de clases en UML. EMF permite crear un meta-modelo a través de diferentes medios, por ejemplo, XML, anotaciones Java, XML o UML. Además EMF proporciona un framework para almacenar la información del modelo. Un ejemplo sencillo de la utilidad de EMF es el siguiente: Imaginemos que deseamos construir una aplicación para manipular mensajes escritos en XML. El primer paso que daríamos sería empezar definiendo el schema del mensaje sin embargo con EMF se puede trabajar ignorando este nivel. Con EMF podemos crear plugins que generen por ejemplo un diagrama de clases UML a partir de este mensaje XML o directamente generar el código Java que implemente las clases del mensaje XML.

2.3. Epsilon

Epsilon es una familia de lenguajes y herramientas para el desarrollo de software dirigido por modelos, entre estas herramientas podemos encontrar: herramientas de transformación de modelos, validación de modelos o generación de código entre otras funcionalidades. Epsilon es distribuido a través de la plataforma de modelado de lenguajes de Eclipse. Epsilon proporciona multitud de lenguajes y herramientas para trabajar con modelos. Los lenguajes utilizados en este proyecto son EOL (Epsilon Object Language), ETL (Epsilon Transformation Language) y EGL (Epsilon Generation Language) también ha sido utilizado EUnit como herramienta para validar el código escrito por el generador de código Cassandra-CQL. Estos lenguajes y herramientas son descritos a continuación.




Figura 2.2: Ejemplo metamodelo casa

2.3.1. Epsilon Object Language

[2.1] Epsilon Object Language (EOL) es un lenguaje de programación imperativo utilizado para crear, consultar y modificar los modelos EMF. Según [2.1], EOL se puede considerar un lenguaje mezcla de Javascript y OCL, que combina lo mejor de ambos lenguajes. Como tal, proporciona todas las características habituales imperativas que se encuentran en Javascript (por ejemplo, la secuencia de la declaración, las variables, bucles for y while, etc) y todas las características interesantes de OCL como las operaciones sobre colecciones, por ejemplo `Sequence{1..5}.select(x | x > 3)`.

Para entender mejor el funcionamiento de EOL se expone el siguiente ejemplo. Se ha definido el meta-modelo mostrado en la figura 2.2, este meta-modelo consiste en la representación de una casa y las personas que viven en ella. Las personas tienen un nombre y un atributo booleano que representa si una persona está viva o no. Existe una relación de agregación para reflejar que la casa contiene personas. Una vez creado el meta-modelo podemos crear un modelo como instancia de ese meta-modelo. Un ejemplo de cómo funciona EOL puede ser el siguiente: deseamos saber que personas habitan en la casa y están vivas. La sintaxis correspondiente sería la siguiente (figura 2.3).

Como vemos la sintaxis es muy similar a cualquier lenguaje orientado a objetos, podemos manipular y consultar los objetos del modelo, sin embargo EOL no nos permite la definición de clases.

```
-----  
for (person in Person.all){  
  if (person.alive == true) {  
    person.name.println();  
  }  
}  
  
//Podemos realizar lo mismo de la siguiente manera:  
  
Person.all.select(r|r.alive==true).name.println();  
-----
```

Figura 2.3: Ejemplo código EOL

2.3.2. Epsilon Transformation Language

[2.1] Epsilon Transformation Language (ETL) es un lenguaje de transformación modelo a modelo basado en reglas (Model to Model-M2M). ETL proporciona las características estándar de un lenguaje de transformación, también nos permite manipular los modelos de entrada y salida así como su código fuente. ETL tiene su propia sintaxis sin embargo utiliza el lenguaje EOL como base.

Recordando el ejemplo de la Red de computadores y el Grafo detallado en el capítulo anterior (sección 1.2). Deseamos realizar la transformación de un modelo de tipo grafo a un modelo de tipo red para ello definiremos una serie de reglas de transformación utilizando para ello ETL. En primer lugar necesitamos definir el modelo del grafo para poder realizar la transformación a un modelo de tipo Red. La figura 2.4 muestra el código que realiza el proceso de transformación de un Grafo a una Red.

En este código encontramos solo una regla. Esta regla transforma aristas del grafo a cables de la red. La primera instrucción copia el nombre de la arista al cable. A continuación la primera condicional cuestiona si esa arista tiene un padre definido en caso afirmativo asigna el cable a la red. A continuación por cada nodo se crea o bien un PC o un router dependiendo del color del nodo que se esté analizando (rojo-PC, azul-Router). En siguiente lugar se asigna el nodo creado al cable correspondiente y finalmente se añade a la red. Este proceso se repite por cada arista del grafo. Una vez ejecutado este código dado un modelo de entrada de tipo Grafo obtenemos un modelo equivalente de tipo Red que cumple las reglas definidas en el meta-modelo.

2.3.3. Epsilon Generation Language

[2.1] [2.4] Epsilon Generation Language (EGL) es un lenguaje utilizado para la generación de código basado en la transformación de modelos (Model to Text-M2T). EGL puede ser utilizado para transformar modelos en cual-

```

rule Arista2Cable
transform a : Grafo!Arista
to r : Red!Cable {
    r.nameCable = a.nombreArista;
    if (a.parent.isDefined()) {
        r.parent=Red;
        for (nodoArista in a.children) {
            if(nodoArista.color=TColor#R){
                var PC : new Red!PC;
                PC.nameNodo="PC"+iPC;
                r.children.add(PC);
                iPC=iPC+1;
            }
            else{
                var Router : new Red!Router;
                Router.nameNodo="Router"+iRouter;
                r.children.add(Router);
                iRouter=iRouter+1;
            }
        }
    }
}

```

Figura 2.4: Ejemplo código ETL

quier tipo de lenguaje, por ejemplo código ejecutable Java, código HTML o incluso aplicaciones completas que comprenden el código en varios lenguajes (por ejemplo, HTML, Javascript y CSS). En este proyecto se utilizara EGL para la generación de código Cassandra Query Language (CQL) a partir de modelos UML 2.0.

Cada plantilla de EGL contiene varias secciones. Cada sección puede ser estática o bien dinámica. Una sección estática contiene texto que aparecerá en la salida generada por la plantilla. Una sección dinámica comienza con la secuencia '[' y termina con la secuencia '%]'. La sección dinámica contiene lenguaje EOL. La figura 2.5 muestra como se realiza la generación de código HTML utilizando para ello el modelo generado de una red a partir de un grafo (ver sección anterior).

Como vemos en el código la integración del código EGL junto con HTML es total, en este sencillo código se genera una página HTML con una tabla que muestra varias filas, una fila por cada conexión entre dos componentes de la red.

2.4. Cassandra

Esta sección realiza una breve descripción sobre Cassandra, desde su historia, arquitectura, sintaxis y otras características que explican como es

```

-----
[%
    var red: Red := Red.allInstances().at(0);
%]

<html>
    <head>
        <title> Red </title>
    </head>
    <body>
        <h1>Conexiones</h1>
        <table border="1">
            <col style="width: 200px" />
            <col style="width: 100px" span="3" />
            [% for (conexiones in red.conexiones){%]
            <tr>
                <th scope="row">[%=conexiones.nameCable%]</th>
                [% for (nodos in conexiones.children){%]
                <td>[%=nodos.nameNodo%]</td>
                [% }%]
            </tr>
            [% }%]
        </table>
    </body>
</html>
-----

```

Figura 2.5: Ejemplo código EGL

el sistema de bases de datos no relacional escogido para este proyecto de fin de carrera.

Desde que nació SQL en el año 1974 se ha convertido en el lenguaje de consultas utilizado por excelencia. En los últimos años ha surgido otra vertiente denominada NoSQL, esta vertiente surge por la necesidad de manejo de grandes volúmenes de información no estructurada, distribuida y accedida con la mayor rapidez posible. NoSQL es literalmente (como es evidente) la combinación de dos palabras: No y SQL, hoy en día este término se utiliza para denominar todas las bases de datos que no siguen los principios de los sistemas de gestión de bases de datos relacionales tradicionales. Es usado en plataformas como Facebook o Twitter. Podemos encontrar varios tipos de bases de datos no relacionales, por ejemplo: Bases de datos documentales, bases de datos orientadas a columnas, orientadas a grafos ente otros.

Existen varias diferencias entre estos sistemas NoSQL y sistemas SQL, las principales características de NoSQL que difieren de SQL son:

1. NoSQL no garantiza las propiedades ACID (atomicidad, coherencia, aislamiento y durabilidad).
2. No utiliza SQL como lenguaje de consultas. Algunas bases de datos

no relacionales utilizan SQL como lenguaje de apoyo sin embargo la mayoría utilizan su propio lenguaje de consultas como por ejemplo Cassandra que utiliza CQL.

3. No está permitido el uso de joins ya que al manejar grandes volúmenes de información una consulta con un join puede llegar a sobrecargar el sistema.
4. Escalan horizontalmente y trabajan de manera distribuida por lo que la información puede estar en distintas maquinas y el añadir nodos mejora el rendimiento.
5. Resuelven problemas de altos volúmenes de información

En este proyecto de fin de carrera se utiliza Cassandra como sistema de bases de datos no relacional. Apache Cassandra fue diseñado por Avinash Lakshman (uno de los creadores de Amazon's Dynamo) y Prashant Malik (Ingeniero de Facebook), en estos momentos se encuentra en producción para Facebook. Dentro del mundo de las bases de datos no relaciones Cassandra es considerada un híbrido de los sistemas orientados a columnas y las bases de datos basadas en clave-valor. Las basadas en clave-valor tienen como peculiaridad que almacenan los datos en forma de columna. Esto permite el acceso a los datos de forma rápida, básicamente, utilizan una tabla hash en la que existe una clave única y un puntero a un elemento de datos en particular. Los sistemas basados en clave-valor son aquellos que asocian los valores a una determinada clave esto permite la recuperación y escritura de información de forma muy rápida y eficiente.

Cassandra reúne las tecnologías de sistemas distribuidos de Amazon Dynamo y el modelo de datos BigTable de Google. Por ejemplo, al igual que Dynamo, es consistente. Como BigTable, proporciona un modelo de datos basado en column families siendo considerado el sistema orientado a columnas más popular. Las bases de datos basadas en Cassandra son soluciones utilizadas cuando es necesaria escalabilidad y alta disponibilidad sin comprometer el rendimiento. Escalabilidad lineal y tolerancia a fallos o infraestructura en la nube lo convierten en la plataforma idónea para datos de misión crítica. Además proporciona gran estabilidad en cuanto a la replicación de datos a través de múltiples datacenters, consiguiendo una menor latencia para sus usuarios y la tranquilidad de que no existan pérdidas de datos ante caídas. Cassandra utiliza el lenguaje de consultas CQL (Cassandra Query Language) con una sintaxis muy similar a SQL aunque mas limitado que este. Como herramienta de manipulación y administración de datos se utiliza DataStax OpsCenter que ofrece una interfaz de usuario basada en navegador que sirve para la gestión y monitorización de los cluster Cassandra en una única terminal de administración.

A continuación se explican brevemente algunos términos que hay que tener en cuenta a la hora de trabajar con Cassandra. En Cassandra un

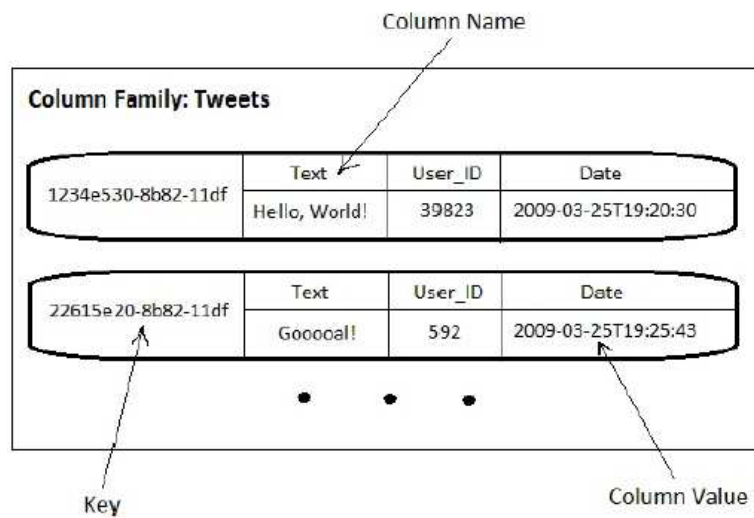


Figura 2.6: Estructura column family

keyspace es el equivalente a un schema en los sistemas de bases de datos relacionales. El conocido término de tabla en las bases de datos relacionales tiene su equivalente en Cassandra llamado column family, las column families se guardan en ficheros separados y son ordenadas por su key. Una columna es la unidad de almacenamiento básica, está formada de tres campos: Nombre, valor y timestamp. El nombre y el valor se almacena como una matriz de bytes sin procesar y pueden ser de cualquier tamaño. Los tres valores anteriores son introducidos por el cliente, incluido el timestamp. Un ejemplo de la estructura de una column: Por lo tanto un keyspace puede

Nombre de la columna	Username
Valor de Username	Ignacio
Timestamp	123456789

Cuadro 2.1: Ejemplo estructura columna

contener varias column families y una column family a su vez contiene varias columnas. La estructura de una column family queda como se puede observar en la figura 2.6.

En cuanto a la sintaxis del lenguaje CQL es muy similar a SQL, CQL contiene sintaxis ya conocida de SQL como INSERT, DELETE, UPDATE, INSERT, ... La Figura 2.7 refleja un ejemplo breve de código CQL ejecutable.

Conceptos relacionados con Cassandra son ampliados en el siguiente capítulo a la hora de definir el meta-modelo de Cassandra.

```
DROP KEYSPACE twitter;

CREATE KEYSPACE twitter
WITH replication = {'class':'SimpleStrategy', 'replication_factor':2};

USE twitter;

CREATE TABLE Tweet(
    UUID text,
    usernameTw text,
    body text,
    PRIMARY KEY(UUID)
);

CREATE TABLE User(
    username text,
    password text,
    followers set<text>,
    followings set<text>,
    tweets_written list<text>,
    PRIMARY KEY(username)
);
```

Figura 2.7: Ejemplo código CQL

2.5. Planificación

El objetivo de este proyecto de fin de carrera es la implementación de un generador de código Cassandra a partir de modelos UML. El proceso de desarrollo así como el de aprendizaje que se ha seguido para la realización del proyecto es descrito a continuación.

La primera tarea como es evidente consistió en adquirir los conocimientos necesarios para el desarrollo del proyecto. En primer lugar todo lo relacionado con el proceso de modelado de un lenguaje y transformación de lenguajes [kleppe]. También fueron necesarios conocimientos sobre la Ingeniería y el Desarrollo Dirigido por Modelos, así como de la sintaxis, arquitectura y funcionamiento de Cassandra.

A continuación se comenzó a trabajar con la herramienta Epsilon, sus lenguajes EOL, EGL, ETL y finalmente EUnit como herramienta para las pruebas de los modelos y código generados. Además el lenguaje para la definición de lenguajes de modelado Eclipse Modeling Framework (EMF). Para conocer cómo funcionaban estos lenguajes se desarrollaron una serie de casos prácticos para familiarizarse con los métodos de transformación así como con la herramienta, para ello se realizó el proceso completo para crear un generador de código desde la transformación entre modelos hasta la transformación modelo-código. Estos casos de prueba son los que se exponen

en la sección de Epsilon (sección 2.3).

Una vez conocido estos conceptos se estudiaron las reglas de transformación a aplicar para transformar un modelo UML a un modelo Cassandra, estas reglas fueron propuestas por [pabloCassandra].

Tras estas tareas de adquisición de conocimientos se comenzó a trabajar en el generador de código Cassandra empezando por la transformación de modelos UML a modelos Cassandra. Estas transformaciones son expuestas en el siguiente capítulo. Una vez finalizada la transformación se comenzó a trabajar en el generador de código Cassandra, esta tarea es descrita en el capítulo 5. Tras realizar dicha tarea se realizaron una serie de casos de prueba para verificar si los resultados que otorgaba el generador de código eran los esperados, para esta tarea utilizamos la herramienta EUnit. Finalmente y tras generar varios casos de ejemplo se instaló DataStax OpsCenter y Apache Cassandra, se ejecutaron los resultados generados y se comprobó su correcto funcionamiento.

2.6. Sumario

Durante este capítulo se han descrito los conceptos necesarios para lograr comprender el ámbito y el alcance de este proyecto, se ha descrito el caso de estudio planteado en el proyecto. También se ha hablado sobre tecnologías implicadas en el desarrollo del generador de código, así como de Cassandra y su arquitectura, Epsilon los lenguajes utilizados y herramientas utilizadas. El siguiente capítulo describe los primeros pasos para la realización del generador de código, el primer paso consiste en la definición de reglas de transformación entre modelos llamadas "Model to Model" (M2M). Además se continúa el caso de estudio planteado en este capítulo, se define el meta-modelo de Cassandra y se definen las reglas de transformación entre modelos UML y Cassandra.

Capítulo 3

Transformación modelo a modelo

Este capítulo describe el primer paso del proceso de transformación de acuerdo al proceso de desarrollo dirigido por modelos. El principal objetivo de esta fase es la transformación de un modelo definido en UML a un modelo en Cassandra. Para ello en primer lugar realizaremos la definición de un meta-modelo que defina el modelado en Cassandra. En segundo lugar debemos definir las reglas de transformación para convertir un modelo UML a un modelo en Cassandra, para lograr esto utilizaremos el lenguaje Epsilon Transformation Language (ETL). A continuación se presenta un caso de estudio en el que se van a aplicar las reglas de transformación ETL que se han definido. Finalmente el sumario con las conclusiones de este capítulo.

Índice

3.1. Introducción	23
3.2. Metamodelo Cassandra	24
3.3. Transformación de Modelo UML a Cassandra	26
3.4. Caso de estudio transformación modelo a modelo	30
3.5. Sumario	31

3.1. Introducción

A la hora de desarrollar el generador de código necesitamos establecer cuales van a ser los modelos de origen y de salida, en este proyecto de fin de carrera y como se especifica en capítulos anteriores uno de los pasos previos a la construcción del generador de código consiste en transformar un modelo UML en un modelo Cassandra para ello es necesario un meta-modelo que defina Cassandra y un meta-modelo de UML, en cuanto al meta-modelo origen basado en UML 2.0 utilizaremos el que nos proporciona la propia

plataforma Epsilon. Para la construcción del meta-modelo de Cassandra utilizaremos EMF. Este tema es abordado en la siguiente sección de este capítulo.

El siguiente paso consiste en establecer una serie de reglas de correspondencia entre el modelo de entrada y el modelo de salida. Estas reglas han de contemplar los distintos tipos de elementos que pueden aparecer en ambos lenguajes, así como elementos que no aparecen en uno de los dos lenguajes y tiene importancia en el otro. La Sección 3.3 describe dichas reglas y parte del código desarrollado para llevarlas a cabo. En este caso, consiste en establecer reglas de correspondencia entre elementos del modelado UML 2.0 y elementos del modelado Cassandra, para así crear el generador de código Cassandra Query Language (CQL). Para la definición de estas reglas se ha utilizado el lenguaje Epsilon Transformation Language (ETL) y el lenguaje Epsilon Object Language (EOL). Tras implementar estas reglas y comprobar que son funcionales se puede implementar el generador de código pero este tema se trata en el siguiente capítulo.

El presente capítulo describe este proceso de desarrollo. En resumen, la Sección 3.2 describe como se ha realizado el lenguaje de modelado de Cassandra (definición del meta-modelo). La Sección 3.3 presenta las correspondencias definidas entre los elementos UML 2.0 y elementos de Cassandra así como el código necesario para llevar a cabo estas correspondencias, finalmente la sección 3.4 muestra el caso de estudio presentado en el capítulo anterior.

3.2. Metamodelo Cassandra

Como habíamos descrito en el capítulo anterior la base del proceso de transformación entre modelos parte del meta-modelo. Previo paso a la definición de las reglas de transformación entre modelos necesitamos definir un meta-modelo de origen y un meta-modelo de destino. El meta-modelo de UML 2.0 utilizado en este proyecto como origen de la transformación es el que nos proporciona Epsilon, dicho meta-modelo sigue el estándar de UML 2.0. A parte del meta-modelo de UML nos hace falta un meta-modelo que defina el lenguaje de modelado de Cassandra. Dicho meta-modelo fue proporcionado por Pablo Sánchez Barreiro. Este meta-modelo se construyó por medio de la abstracción de las principales características de Cassandra. El meta-modelo sufrió algunos cambios respecto al inicial debido a exigencias y variantes que sufrió el proyecto. La Figura 3.1 muestra como se ha definido el lenguaje de modelado de Cassandra con EMF, como vemos se puede diseñar un lenguaje de manera muy similar a la definición de clases en UML. Este tipo de modelo es el origen del proceso de transformaciones entre modelos que queremos crear. A continuación se detallan los aspectos más importantes del meta-modelo de Cassandra.




Figura 3.1: Metamodelo Cassandra

De acuerdo con la arquitectura de Cassandra, el elemento raíz de cualquier esquema orientado a columnas es el keyspace, el keyspace es el equivalente a una base de datos en el modelo relacional, la meta-clase keyspace cuenta con los meta-atributos: nombre utilizado para denominar el keyspace, [cassandra] replicationFactor que representa el número de servidores de Cassandra de los que se debe guardar un registro u obtener una respuesta al recuperar algún registro y replicaPlacementStrategy es la estrategia de replicación que se va a tomar, dentro de estas estrategias de replicación encontramos tres tipos:

1. SimpleStrategy: Es la estrategia de replicación utilizada por defecto al crear un keyspace utilizando Cassandra. Es utilizada para clústeres de datacenters simples.
2. NetworkTopologyStrategy: Utilizada cuando el clúster es desplegado a través de múltiples data centers. Esta estrategia especifica cuántas réplicas se desean en cada data center.
3. OldNetworkTopologyStrategy: Se utiliza para proporcionar retro-compatibilidad con instalaciones de Cassandra antiguas.

A continuación tenemos la meta-clase ColumnFamily equivalente a las tablas en el modelo relacional, dentro de esta meta-clase encontramos dos tipos: las StaticColumnFamily y las DynamicColumnFamily. Recordamos que las static column family son el equivalente a las tablas en el modelo relacional, sin embargo las dynamic column family son utilizadas para la recuperación de datos eficiente, algo similar a las vistas del modelo relacional.

En cuanto a la definición de la primary key, las column families estáticas siguen una definición de claves clásica por lo que en el meta-modelo no se refleja, sin embargo las column families dinámicas tienen una definición de la primary key especial. A la hora de definir esta primary key hay que tener

en cuenta el orden, en CQL el orden de definición de las claves importa, en la primera columna de la primary key se define la partition key, esta tiene la propiedad de que todas las filas que comparten la misma partition key se almacenan en el mismo nodo físico. Además, la inserción, actualización o eliminación de filas que comparten la partition key para una column family determinada se realizan de forma atómica. Es posible tener una partition key compuesta, es decir, una partition key formada por varias columnas, en CQL esto se define utilizando paréntesis para delimitar el conjunto de partición. En la siguiente columna se define la clustering key utilizada para la recuperación de filas de manera eficiente. En el meta-modelo solo tendremos en cuenta las partition key puesto que las columnas que no son definidas como partition key se toman como cluster key. Aunque en siguientes secciones esta información se amplía, el resumen de la definición de column families dinámicas es la siguiente: PRIMARY KEY((partitioning key_1, ... partitioning key_n), clustering key_1 ... clustering key_n)

La siguiente meta-clase es Column, esta meta-clase contiene los valores que se almacenan en las column families, estas columns tienen como meta-atributos el nombre y un tipo de dato. Dentro de los tipos de datos que pueden darse en una columna encontramos dos meta-tipos, PrimitiveType y DataStructureType. PrimitiveType define los tipos primitivos, por ejemplo entero, texto, uuid, etc.. DataStructureType define las colecciones. Estas colecciones pueden ser de dos tipos: MapType o bien CollectionType, ambas colecciones tienen un meta-atributo llamado KeyType para definir el tipo primitivo que utilizan. MapType cuenta con un meta-atributo llamado baseType de tipo primitivo que define el segundo tipo de dato del mapa. Dentro de CollectionType encontramos un meta-atributo llamado kind que define el tipo de colección que vamos a utilizar, esta puede ser o bien tipo set o tipo list. Más adelante se explica que características reúne cada colección y mapa y cuando se utilizan.

3.3. Transformación de Modelo UML a Cassandra

Una vez definido el meta-modelo de Cassandra podemos establecer las reglas de transformación entre modelos UML y modelos Cassandra, para ello utilizaremos Epsilon Transformation Language (ETL). Recordamos que el lenguaje ETL es el lenguaje que utiliza Epsilon para la transformación entre modelos basado en reglas. Las reglas de transformación son definidas en [docPablo]. A continuación se detalla cómo se han implementado dichas reglas.

3.3.1. Transformación del modelo

El modelo UML se considera el elemento raíz que contiene como es evidente, todos los elementos del modelo, este modelo de datos se transforma

en el keyspace para el repositorio de Cassandra. El nombre del keyspace corresponderá al que se haya escogido para el modelo de datos UML. Los keyspace permiten agrupar entidades tales como column families, columns.. De esta forma, se pueden tener varios Key Spaces en el mismo proyecto independientes entre sí.

3.3.2. Transformación de clases

Se han definido dos reglas ETL que transforman una clase definida en UML a una static column family de Cassandra (el equivalente a una tabla en el sistema de bases de datos relacionales). La primera regla es definida para las clases que tengan un atributo clave definido, para ello se utiliza la propiedad isID de UML, esta propiedad define que ese atributo identifica a la clase de forma única. La segunda regla es para las clases sin atributo clave definido. El proceso de transformación es similar en ambas reglas, en primer lugar se transforma la clase UML a una column family de Cassandra, se asigna la column family al keyspace que le corresponde, se copia el nombre de la clase a la column family y se añade al conjunto de column families del keyspace. La segunda regla es utilizada para las clases sin atributo clave, en este caso se crea un atributo que va a ser la clave de esa column family (ya que esta no tiene), dicha clave tendrá de nombre, el nombre de la clase más el distintivo _ID y será de tipo uuid. Dichas reglas están definidas en el punto 5.3 del documento [docPablo].

3.3.3. Transformación de atributos

La siguiente regla define como se ha transformado un atributo del modelo UML a una columna del modelo Cassandra. La definición básica es que un atributo UML corresponde a una columna de Cassandra. Para ello definimos una guarda ETL para que la transformación se haga solo de los atributos de las clases y no de los atributos de la relación ya que al importar los modelos UML existen atributos ajenos al modelo de datos que son importados a Epsilon. A continuación se realiza un filtro para evitar la adición de columnas que no pertenezcan al modelo de datos. Una vez hecho esto hay que diferenciar dos tipos de atributos, aquellos cuya multiplicidad sea igual a 1 y aquellos atributos con multiplicidad mayor de 1. En cuanto a los atributos de multiplicidad igual a 1 se realiza la transformación del atributo a columna copiando su tipo de dato. Respecto a los atributos de tamaño mayor de 1 se aplica la siguiente regla: Aquellos atributos que se hayan definido en el modelo UML como únicos y no ordenados son transformados como tipo set de Cassandra. En caso contrario se definen como tipo list. Una vez transformado el atributo en un set o en una list, en ambos casos se realiza la transformación correspondiente del tipo primitivo UML a Cassandra (viene descrita en la última sub-sección), se realiza una copia

```

-----
//5.5 Attribute with primitive type transformation
rule Attribute2Column
transform attribute : UML!Property
to column : nosql!Column {
    guard: (("+"attribute.qualifiedName).contains("Data::") and attribute.type.isKindOf(UML!PrimitiveType))

    //filtramos para evitar añadir columnas ajenas al modelo de datos
    for(cfamil in kspace.columnFamilies){

        if(attribute.qualifiedName=="Data::"+cfamil.name+"::"+attribute.name){

            //5.5 Attribute with primitive type transformation->Attributes with upper bound = 1
            if(attribute.upper=1){
                //transformacion del atributo en una columna basica
                var type : new nosql!PrimitiveType;
                type.kind=umlType2modelType(attribute.type.name);
                column.type=type;
            }
            //5.5 Attribute with primitive type transformation->Attributes with upper bound > 1
            else if(attribute.upper<>0){
                //transformacion del atributo en un set o list
                var ctype : new nosql!CollectionType;

                if(attribute.isUnique and not attribute.isOrdered)//set
                    ctype.kind=nosql!CollectionTypeType#set;
                else//list
                    ctype.kind=nosql!CollectionTypeType#list;

                ctype.keyType=umlType2modelType(attribute.type.name);
                column.type=ctype;
            }

            column.name=attribute.name;
            cfamil.columns.add(column);

            //5.1 Assignment of keys to classes
            if(attribute.isID)
                cfamil.primaryKey.add(column);
        }
    }
}
-----

```

Figura 3.2: Regla de transformación XX

del nombre y se añade la columna ya transformada a la column family correspondiente. Finalmente en caso de que el atributo sea clave de la clase se añade a la column family como primary key. El código correspondiente a esta regla es el que se puede observar en la figura 3.2

3.3.4. Transformación de asociaciones

La siguiente regla define como se realiza la transformación de los atributos de las asociaciones entre clases UML. En primer lugar hay que diferenciar como se tratan las asociaciones, existen dos tipos de asociaciones: aquellas asociaciones cuyo extremo tiene una cardinalidad igual a uno y aquellas con una cardinalidad mayor de uno.

Para los extremos con cardinalidad igual a uno se crea una columna que será añadida en la column family del otro extremo de la relación, esta columna nueva es una copia de la columna que es primary key en la column family fuente, el nombre de la nueva columna es la composición del nombre de la column family y del nombre de la primary key, el tipo de la nueva columna es el mismo que el de la columna primary key de la column family fuente. Esto se comprende mejor con el caso de estudio propuesto en la sección siguiente.

Para los extremos con cardinalidad mayor de uno, se crea una dynamic column family. Recordamos que la primary key de este tipo de column family esta compuesta de dos tipos de columnas: La partition key y la cluster key. La transformación utilizada para este tipo de column family es la siguiente: Esta column family dinámica está compuesta de dos columnas, la primera columna juega el papel de partition key y la segunda columna de cluster key, la primera columna se construye de la misma manera que el caso anterior, se copia el nombre y el tipo de la primary key de la column family extremo de la asociación fuente. La segunda columna de la misma manera toma los datos nombre y tipo de la primary key del otro extremo de la asociación. El nombre de la column family será la concatenación del nombre de las column family de ambos extremos de la asociación (primero fuente, segundo extremo fin de la asociación). En resumen la transformación de la primary key en las column family dinámicas es la siguiente:

1. Partition Key: Primera columna (fuente de la asociación).
2. Clustering Key: Segunda columna (extremo de la asociación).

3.3.5. Transformación de tipos primitivos

En cuanto a la transformación de variables de tipo primitivo hemos definido una operación básica de correspondencia entre tipos (no una regla), de esta manera podemos convertir un tipo primitivo UML a su equivalente en Cassandra. Las correspondencias definidas serían las siguientes:

UML	Cassandra
string	text
int	int
date	timestamp
uuid	uuid
float	float
double	double
boolean	boolean
char	varchar

Cuadro 3.1: Equivalencias tipos primitivos UML-Cassandra

3.4. Caso de estudio transformación modelo a modelo

Como se explicaba en el capítulo 2 (sección 2.1), el objetivo consiste en la creación de un generador de código de una versión simplificada de Twitter llamada Twissandra. En esta sección se reproducirán los procesos M2M y M2T en el siguiente capítulo, todo esto bajo el proceso de desarrollo dirigido por modelos. Esta sección está dedicada a describir la transformación del modelo UML de Twissandra a un modelo Cassandra, para ello partimos del modelo UML de la figura 2.1. Una vez establecidas las reglas de transformación entre modelos podemos realizar la generación del código aunque esto se analizará en el siguiente capítulo.

En primer lugar, por cada paquete estereotipado como «dataModel», se crea un nuevo keyspace. El nombre del keyspace será el nombre que se ha definido en el modelo de datos UML. Los atributos restantes de las meta-clases del keyspace se establecen en sus valores definidos por defecto en el modelo UML. A continuación, todos los elementos correspondientes de ese paquete se procesan.

A continuación se realiza un marcado del atributo username de la clase User como clave, ya que el parámetro isID del atributo username en el modelo UML está marcado como true. En el caso de las clases FollowingRelationship y la clase Tweet al no tener un atributo marcado como clave generamos dos columnas clave automáticamente para cada clase, llamadas FollowingRelationship_id y tweet_id respectivamente. La clase User del modelo UML es transformada en una column family llamada User. Una vez procesadas las clases UML y transformarlas a su correspondiente column family se proceden a transformar los atributos y asociaciones. De manera similar para aquellos atributos del modelo UML cuya multiplicidad sea igual a uno se realiza una transformación simple, por ejemplo el atributo username y password se transforman en dos columnas Cassandra, ambas

del tipo text. Estas columnas están contenidas en la column family User. De la misma forma se transforman los atributos body y time de la clase Tweet y el atributo timestamp de la clase FollowingRelationship. En el caso del atributo del modelo UML email cuya multiplicidad es mayor de uno y tiene las propiedades isUnique establecida en false y la propiedad isOrdered establecida en false (en el modelo no se puede apreciar pero está configurado así en el modelo UML), se transforma este atributo en una colección de tipo set llamada email cuyo tipo primitivo será text, esta colección estará dentro de la column family User.

En cuanto a las asociaciones recordamos que tenemos dos tipos, las de multiplicidad igual a uno y las de multiplicidad mayor de uno. Para la asociación de la clase User cuya multiplicidad es igual uno, se crea una nueva columna llamada user_username (recordemos que username es la clave de la column family user) y esta columna es añadida a la column family Tweet. Para las asociaciones de multiplicidad mayor de uno, por ejemplo la asociación llamada userline se crea una dynamic column family llamada User_userline. A continuación una columna llamada user_username de tipo text es añadida a esta column family. Después una columna llamada tweet_id de tipo uuid es añadida (el atributo tweet_id fue creado en la column family tweet al no tener clave). Las columnas user_username y tweet_id son designadas como primary key, la columna user_username será la partition key y la columna tweet_id será la cluster key.

3.5. Sumario

Durante este capítulo se ha descrito todo el proceso "Model to Model"(M2M) realizado. En primer lugar se ha descrito la construcción del meta-modelo de Cassandra, proceso base para la transformación entre modelos. A continuación se han presentado cuales son las reglas que se han utilizado a la hora de transformar cada uno de los elementos de un modelo UML a un modelo Cassandra. Para lograr este objetivo se han definido una serie de reglas escritas en el lenguaje Epsilon Transformation Language (ETL), de esta manera podemos transformar un modelo UML en un modelo Cassandra. La siguiente sección está dedicada a continuar el caso de estudio desarrollado a lo largo del proyecto relacionado con Twissandra, en esta sección se explican como se transforman los elementos que aparecen en el modelo UML de Twissandra a el modelo de Cassandra.

Capítulo 4

Transformación modelo a texto

El capítulo anterior hizo una descripción del funcionamiento y desarrollo del primer paso del proceso de transformación dirigido por modelos, 'Model To model'(M2M). En este capítulo se presenta el siguiente paso del proceso de transformación dirigido por modelos, dicho paso consiste en la transformación del modelo a código, este paso es mas conocido como 'Model To Text'(M2T). En este capitulo se explica como se ha realizado la implementación del generador de código utilizando para ello el lenguaje Epsilon Generation Language (EGL). Además se describe el funcionamiento y desarrollo de los generadores de código así como de las pruebas realizadas para comprobar su correcto funcionamiento.

Índice

4.1. Introducción	33
4.2. Generador de código	34
4.3. Caso de estudio Twissandra	36
4.4. Pruebas	37
4.5. Sumario	37

4.1. Introducción

Una vez establecidas las reglas de correspondencia entre ambos modelos empezamos a desarrollar el generador de código. Este capítulo describe el proceso de desarrollo de los generadores de código. El objetivo de esta fase, es generar un repositorio de datos NoSQL funcional a partir de un modelo de datos UML 2.0. El código generado es código Cassandra Query Language (CQL) que puede ser ejecutado en herramientas que soporten dicho lenguaje. Este proceso es descrito en la Sección 3.2 de este capítulo. De

manera análoga al anterior capítulo la Sección 3.3 esta dedicada a aplicar esta transformación modelo-código al caso de estudio sobre Twissandra. A continuación tras implementar el generador de código el siguiente paso consiste en la implementación de una serie de casos de prueba para comprobar el correcto funcionamiento del generador de código. Esto es explicado en la Sección 3.4. Para la implementación de este generador de código se ha utilizado el lenguaje Epsilon Generation Language (EGL).

En resumen, la Sección 3.2 describe como se ha realizado el generador de código. La Sección 3.3 continua el caso de estudio presentado en el capítulo 2, mientras que la Sección 3.4 describe las pruebas que se han realizado para comprobar el correcto funcionamiento del generador de código.

4.2. Generador de código

Esta sección analiza el proceso de creación del generador de código. El desarrollo del generador de código se ha realizado con el lenguaje Epsilon Generation Language (EGL), este lenguaje es utilizado para la generación de código basado en la transformación de modelos, el lenguaje a generar es Cassandra Query Language (CQL). Este lenguaje de consultas es muy similar a SQL, sin embargo existen pequeñas diferencias que se han citado a lo largo del proyecto por ejemplo: la definición de claves, tipos de dato etc.

El proceso de transformación modelo-código es el siguiente. En primer lugar se realiza la definición del keyspace para ello hay que tomar el nombre del keyspace que parte del modelo transformado Cassandra y la estrategia de replicación (ver capítulo 3, sección 2). A continuación se define la creación de una column family en CQL. Tras determinar el bloque de creación de la column family (CREATE TABLE) se definen las columnas de la tabla. Por cada columna de la column family se obtiene el nombre de la columna y se fija el tipo de dato de la columna (primitivo,map,set/list) junto con su nombre. La definición de estas columnas sería la siguiente.

1. Tipo básico: "nombre columna-tipo primitivo".
2. Map: "nombre columna-map-(tipo primitivo 1,tipo primitivo 2)".
3. Set/list: "nombre columna-set-tipo primitivo".

En la figura 4.1 se muestra parte del código para realizar esto (lenguaje ETL). El resto de código se ha omitido por razones de espacio sin embargo se detalla a continuación.

Tras la definición de la columna se define la primary key. Para la definición de la primary key debemos diferenciar si la column family es dinámica o estática. En caso de ser estática la definición sería la clásica: PRIMARY KEY(ColumnaClave). En el caso de tratarse de una column family dinámica la construcción modelo-código es distinta, la más frecuente es la siguiente:


```

-----
DROP KEYSPACE [%=keyspace.name%];
CREATE KEYSPACE [%=keyspace.name%]
WITH replication = {'class': '%=keyspace.replicaPlacementStrategy%', 'replication_factor': [%=keyspace.replicaFactor%]};

USE [%=keyspace.name%];

[% for (cf in keyspace.columnFamilies){ tableKey="";%]
CREATE TABLE [%=cf.name%](
[% for (cols in cf.columns){ //este for define cada grupo de columnas
s=cols.name.toString();
for (c in cols.type){

if (c.isTypeOf(PrimitiveType)) //definicion del tipo primitivo
s=s+" "+c.kind.toString();

if (c.isTypeOf(MapType)) //definicion del tipo map
s=s+" Map"+"<" +c.keyType.toString()+" "+c.baseType.toString()+">";

if(c.isTypeOf(CollectionType)) //definicion del tipo set o list
s=s+" "+c.kind.toString()+"<" +c.keyType.toString()+">";

}
};
[%}%]
-----

```

Figura 4.1: Regla de transformación Primary Key

PRIMARY KEY(partitioning key, clustering key_1 ... clustering key_n) Sin embargo hay que tener en cuenta que en la construcción y según la documentación de CQL también es posible tener una partition key compuesta, es decir, una partition key formada por varias columnas, para realizar esto se utilizan paréntesis y así delimitamos el conjunto de partición. Quedando una posible definición de la primary key de la siguiente manera: PRIMARY KEY((partitioning key_1, ... partitioning key_n), clustering key_1 ... clustering key_n). Este proceso se repite por cada column family del modelo.

Una vez definido el código EGL podemos poner en funcionamiento el generador de código. El proceso completo sería el siguiente: En primer lugar creamos un modelo UML con cualquier herramienta de modelado, por ejemplo el modelo UML de Twissandra ha sido realizado con la herramienta Magic Draw. A continuación transformamos este modelo UML al modelo Cassandra con los métodos de transformación definidos en el capítulo anterior, una vez obtenido este modelo de Cassandra podemos poner en funcionamiento el generador de código, este proceso con el caso de estudio de Twissandra es descrito en la siguiente sección. Con el código ya generado podemos crear el repositorio de datos Cassandra.

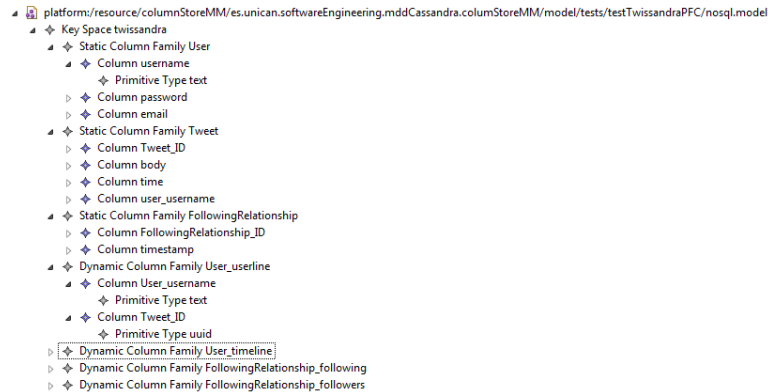


Figura 4.2: Modelo UML Twissandra

4.3. Caso de estudio Twissandra

Una vez definido el funcionamiento del generador de código podemos continuar con el caso de estudio planteado en el segundo capítulo sobre Twissandra. Como se presentó anteriormente el objetivo de este caso de estudio es la generación de código CQL a partir de un modelo UML 2.0. Para ello definimos una serie de reglas de transformación entre modelos y obtuvimos un modelo de Cassandra a partir de un modelo UML que representaba una versión simplificada de Twitter llamada Twissandra. En esta sección se presenta el resultado de la transformación del modelo de Twissandra a código.

Tras obtener el modelo Cassandra de Twissandra (figura 4.2) y tras la definición del generador de código se pone en funcionamiento la transformación modelo-código. El resultado de la transformación se detalla a continuación. El código resultante tras ejecutar el generador de código es el siguiente (figura 4.3).

Como vemos en el código las tres primeras líneas son para borrar el keyspace en caso de que existiera, crearlo y configurar la arquitectura de replicación según estaba especificado en el modelo Cassandra. A continuación se conecta la sesión con el keyspace correspondiente. Por cada column family (sea estática o dinámica) se genera un bloque `CREATE TABLE`. Cada columna de la column family es transformada en una columna de la tabla. La transformación como se contaba en la sección anterior es trivial, sin embargo el problema del generador de código surge a la hora de definir la estructura de la primary key. Las column family estáticas siguen una definición de claves tradicional, sin embargo las column families dinámicas tienen que tener en cuenta que las claves de partición (partition keys) pueden ser compuestas (aunque en este ejemplo no existen). Por ejemplo el caso de `user_userline` las columnas `user_name` y `tweet_id` son designadas como primary key, `user_username` será la clave de partición.

4.4. Pruebas

Una vez implementado el generador de código la siguiente tarea consiste en comprobar que el código generado funciona correctamente. Para ello creamos, una serie de pruebas unitarias que permitan comprobar que el funcionamiento de los generadores de código es correcto para un conjunto de modelos de entrada.

Estas pruebas unitarias se han implementado en EUnit, el lenguaje de definición de pruebas de la suite Epsilon. EUnit funciona de una manera muy similar a JUnit, pero aplicado a los lenguajes de la suite Epsilon, como EGL. Utilizamos EUnit para comprobar que el funcionamiento del generador de código es correcto, para ello se diseñan una serie de casos de prueba y se crea la salida esperada de cada uno de esos casos de prueba de forma manual. A continuación, se ejecuta el caso de prueba creado en EUnit y se comprueba que la salida generada coincide con la esperada, que es la creada manualmente. Además comprobamos con casos específicos que la cobertura del código es del 100

El único problema surge por un problema de defecto en la herramienta EUnit, la función de comparación de ficheros llamada `assertEqualFiles` obliga a que ambos ficheros sean estrictamente iguales por lo que para crear casos de prueba tanto el código de entrada de prueba como el código generado a testear han de ser iguales, espacios y saltos de línea incluidos.

4.5. Sumario

Durante este capítulo se ha descrito el proceso de desarrollo del generador de código. Tras la breve introducción de este capítulo se ha presentado parte del código del generador de código así como la sintaxis de EGL, lenguaje utilizado para construir este generador. Además se ha detallado como se ha realizado este generador de código. A continuación se ha detallado el proceso de transformación del caso de estudio introducido en el capítulo dos de Twissandra. Finalmente se han presentado las pruebas realizadas así como la herramienta utilizada EUnit.

```
DROP KEYSPACE twissandra;
CREATE KEYSPACE twissandra
WITH replication = {'class': 'SimpleStrategy', 'replication_factor': 1};

USE twissandra;

CREATE TABLE User(
    username text,
    password text,
    email set<text>,
    PRIMARY KEY(username)
);

CREATE TABLE Tweet(
    Tweet_ID uuid,
    body text,
    time timestamp,
    user_username text,
    PRIMARY KEY(Tweet_ID)
);

CREATE TABLE FollowingRelationship(
    FollowingRelationship_ID uuid,
    timestamp timestamp,
    PRIMARY KEY(FollowingRelationship_ID)
);

CREATE TABLE User_userline(
    User_username text,
    Tweet_ID uuid,
    PRIMARY KEY((User_username), Tweet_ID)
);

CREATE TABLE User_timeline(
    User_username text,
    Tweet_ID uuid,
    PRIMARY KEY((User_username), Tweet_ID)
);

CREATE TABLE FollowingRelationship_following(
    FollowingRelationship_FollowingRelationship_ID uuid,
    username text,
    PRIMARY KEY((FollowingRelationship_FollowingRelationship_ID), username)
);

CREATE TABLE FollowingRelationship_followers(
    FollowingRelationship_FollowingRelationship_ID uuid,
    username text,
    PRIMARY KEY((FollowingRelationship_FollowingRelationship_ID), username)
);
```

Figura 4.3: Código resultante Twissandra

Capítulo 5

Sumario y Trabajos Futuros

Este capítulo resume el trabajo realizado durante la elaboración del presente Proyecto Fin de Carrera, además se describen brevemente las lecciones, experiencias personales aprendidas y posibles trabajos futuros.

Índice

5.1. Sumario	39
5.2. Experiencia personal	40
5.3. Trabajos futuros	41

5.1. Sumario

Esta memoria de Proyecto Fin de Carrera ha descrito el proceso de desarrollo de un generador de código Cassandra bajo el desarrollo dirigido por modelos.

Como hemos visto el Desarrollo Dirigido por Modelos aporta multiples ventajas a los desarrolladores software, la automatización de los procesos de producción nos permite crear software más rápido llegando a considerar a este paradigma como la verdadera industrialización de la producción de software esto permite a las empresas ahorro en tiempo y costes. La base de la utilización de Cassandra se sostiene en aspectos como la disponibilidad o el manejo de gran cantidad de datos, aspectos que no son facilitados mediante la utilización de bases de datos relacionales tradicionales. Además dentro de las bases de datos no relacionales orientadas a columnas Cassandra es el sistema utilizado por excelencia. En cuanto a la utilización de UML como lenguaje de modelado origen', consideramos que la utilización de modelos UML respecto a modelos diseñados en Cassandra a la hora de crear una base de datos no relacional proporciona una abstracción para aquellos desarrolladores que no estén muy familiarizados con el modelado de bases de datos no relacionales.

A nivel de implementación, el desarrollo del generador de código fue laborioso en términos de adquisición de conceptos ya que el plan de estudios de la carrera de Ingeniería Informática aporta pocos conocimientos en este area. Para ello en primer lugar se estudiaron conceptos relacionados con el modelado de lenguajes [kleppe] para entender y poder trabajar con el meta-modelo de Cassandra, a continuación todo lo vinculado con el Desarrollo y la Ingeniería Dirigida por Modelos, técnicas de transformación (M2M,M2T), ventajas etc.. Finalmente el estudio de todos los lenguajes y herramientas que ofrece la plataforma de Epsilon (ETL, EGL, EOL, EUnit..). Una vez dominados estos conceptos se pusieron en practica todas las nociones aprendidas con una serie de ejemplos sencillos propuestos por el director del proyecto que han sido descritos a lo largo de esta memoria.

Tras estas tareas de estudio, se procedió a la realización del principal objetivo del proyecto: la creación de un generador de código Cassandra que transforma modelos UML a modelos Cassandra. Para ello en primer lugar se hicieron una serie de cambios en el meta-modelo que nos proporcionaron de Cassandra mediante EMF. A continuación se definieron las reglas de correspondencia entre modelos UML y Cassandra y se desarrollaron mediante el lenguaje ETL. Seguidamente y tras realizar el proceso de transformación entre modelos (M2M), se desarrollaron las plantillas para la transformación modelo-código (M2T), para lograr esto se crearon plantillas para generar código CQL, de esta manera obtuvimos el código necesario para crear repositorios de datos en Cassandra. Por último se realizaron una serie de casos de prueba con la herramienta EUnit para comprobar el correcto funcionamiento del generador de código.

La siguiente sección describe las experiencias personales vividas a lo largo del proyecto.

5.2. Experiencia personal

Esta sección describe las experiencias personales acontecidas a lo largo del proyecto.

Las tareas de aprendizaje de lenguajes como EOL, ETL o EGL no resultaron muy costosas sin embargo siempre cuesta adentrarse en materias desconocidas ya que a pesar de que EOL por ejemplo es similar a OCL (Object Constraint Language) son conceptos que no se ven mucho durante la carrera.

En cuanto a la tarea de desarrollo del generador de código se utilizó la herramienta Epsilon que ofrece funcionalidades que facilitan el trabajo de crear generadores de código, sin embargo el mayor problema de estas herramientas es que al ser de reciente creación el numero de errores que surgen durante el desarrollo son molestos y numerosos, por ejemplo existen errores sin identificar durante la ejecución de los casos de prueba. También sur-

gen dificultades a la hora de poner en marcha el generador de código ya que algunos parámetros de configuración de Epsilon no son descritos en los manuales, a pesar de que Epsilon proporciona a los usuarios manuales y tutoriales completos y didácticos pero a nivel elemental. A pesar de algunos infortunios o problemas a lo largo del desarrollo el resultado del trabajo es satisfactorio.

El paradigma del Desarrollo Dirigido por Modelos en mi opinión será una materia básica a la hora de estudiar tecnologías y herramientas que pueden facilitar la vida a las empresas. Personalmente creo que estas tecnologías utilizadas para la automatización de construcción software son parte del futuro y serán materias troncales para futuros alumnos que estudien Ingeniería Informática, ya que permiten a las empresas reducción de costes, ahorro de tiempo y reutilización de componentes tres pilares clave en materia de optimización de los recursos de una empresa software.

5.3. Trabajos futuros

Este proyecto de fin de carrera ha cubierto todos los objetivos planteados desde el principio, es posible que el proyecto deje algún aspecto por completar para que el trabajo presentado tenga la apariencia de un producto profesional sin embargo hay aspectos en los que la herramienta Epsilon ha puesto muchas trabas, por ejemplo: muchos bugs de carácter desconocido, (AÑADIR) Los problemas sin cubrir son comprensibles ya que al ser una herramienta desarrollada por terceros estos defectos están fuera de nuestro alcance por lo que difícilmente pueden ser subsanados con la herramientas. Además hay que tener en cuenta que Epsilon es una herramienta aún joven. Otro posible futura funcionalidad encontrada es que Epsilon ofrezca facilidades para el empaquetado del generador de código de manera que se pueda crear un plug-in que se integre en Eclipse, de esta manera cualquier usuario de Eclipse con la instalación sencilla del plug-in podría ejecutar este generador de código de manera muy sencilla. Otra de las tareas que se podría desarrollar es la integración del generador de código con Apache Cassandra esto podría resultar útil a los desarrolladores ya que con el diseño UML del sistema a implementar se podría generar el repositorio de datos de manera muy sencilla.