

Índice general

1. Introducción	1
1.1. Contexto del proyecto	1
1.2. Antecedentes: Ingeniería Dirigida por Modelos y Desarrollo Dirigido por modelos	3
1.3. Motivación y Objetivos	8
1.4. Estructura del Documento	8
2. Antecedentes y Planificación	11
2.1. Caso de estudio: Generador de código CQL-Cassandra	11
2.2. EMF	11
2.3. Epsilon	12
2.3.1. Epsilon Object Language	12
2.3.2. Epsilon Transformation Language	14
2.3.3. Epsilon Generation Language	15
2.4. Cassandra	15
2.5. Planificación	17
2.6. Sumario	19
3. Model to text	21
3.1. Introducción	21
3.2. Metamodelo Cassandra	21
3.3. Transformación de Modelo UML a Cassandra	23
3.4. Caso de estudio	26
3.5. Pruebas	26
3.6. Sumario	26

Índice de figuras

1.1. Capas del modelado de lenguajes	4
1.2. (a) Metamodelo, (b) Sintaxis concreta, (c) Sintaxis grafica . .	5
1.3. Proceso de transformación de un modelo	6
1.4. Metamodelo de un grafo	7
1.5. Metamodelo de una red	7
1.6. Resultado transformación HTML	8
2.1. Ejemplo metamodelo casa	13
2.2. Ejemplo código EOL	13
2.3. Ejemplo código ETL	14
2.4. Ejemplo código EGL	16
2.5. Ejemplo código CQL	18
3.1. Metamodelo Cassandra	22
3.2. Regla de transformación XX	25

Índice de cuadros

Capítulo 1

Introducción

Este capítulo sirve de introducción a la presente Memoria de Proyecto de Fin de Carrera. En primer lugar se realiza una breve introducción de los conceptos generales del proyecto. La siguiente sección describe conceptos orientados a la Ingeniería de Lenguajes Dirigida por Modelos y al Desarrollo Dirigido por Modelos. La tercera sección describe las motivaciones y objetivos. La última sección está dedicada a describir la estructura del documento.

Índice

1.1. Contexto del proyecto	1
1.2. Antecedentes: Ingeniería Dirigida por Modelos y Desarrollo Dirigido por modelos	3
1.3. Motivación y Objetivos	8
1.4. Estructura del Documento	8

1.1. Contexto del proyecto

El término conocido como modelado ha sido asociado a las bases de datos y a la gestión de datos durante décadas. [1] El modelo entidad-relación (ER) y el conjunto de reglas para la transformación de un modelo ER en un esquema relacional es un ejemplo conocido y utilizado. Recientemente las nuevas tecnologías de gestión de datos, también conocidas como tecnologías NoSQL, han surgido como respuesta a los nuevos retos y demandas de las aplicaciones de Internet modernas. Estas tecnologías se han centrado en el nivel de aplicación, al carecer de un soporte de modelado adecuado. Las aplicaciones de Internet emergentes, como las redes sociales (por ejemplo, Twitter) o tiendas online conocidas (por ejemplo, Amazon), están generando nuevos desafíos en materia de almacenamiento y gestión de datos. Por ejemplo, la disponibilidad se está convirtiendo en un aspecto crítico ya que una caída del sistema puede generar grandes pérdidas. Del mismo modo,

estas aplicaciones tienen que soportar picos de carga altos de los usuarios, en los que estos usuarios ejecutan operaciones muy similares (por ejemplo, publicar un mensaje corto en una red social después de un evento popular, como la final de la Super Bowl o unas elecciones presidenciales).

En este contexto las bases de datos relacionales tradicionales han resultado ser insuficientes para satisfacer estas nuevas exigencias. Las tecnologías NoSQL (Not Only SQL) [2] tienen como objetivo hacer frente a estas nuevas exigencias. NoSQL sacrifica algunas de las ventajas bien conocidas de los sistemas de gestión de bases de datos relacionales, como la integridad o la manipulación de transacciones, con el fin de proporcionar una mejor escalabilidad y un mayor rendimiento. Siguiendo esta idea, varios sistemas NoSQL, como Cassandra [3], HBase [4] o MongoDB [5], han aparecido en los últimos años.

Sin embargo, las tecnologías NoSQL no están aún integradas en los procesos de desarrollo de software que ayudan a los ingenieros de software en la construcción de repositorios NoSQL desde las primeras etapas del ciclo de vida del software hasta el lanzamiento del producto. Este trabajo tiene como objetivo contribuir con una herramienta para superar esta barrera, proporcionando una herramienta que genera bases de datos NoSQL.

Por lo tanto, este trabajo se centrará en la creación de un generador de código que transforma un modelo de datos conceptual UML en código para la creación de un repositorio de datos NoSQL. Para este trabajo, nos centraremos en los sistemas orientados a columnas. Las razones son las siguientes: (1) sistemas orientados a columnas son de uso general, mientras que otros sistemas NoSQL, tales como, los de gestión de documentos, son más específicos a ese dominio; y, (2) que tenía experiencia previa en el manejo de estos sistemas. Más concretamente, hemos decidido utilizar Cassandra [3] como sistema NoSQL orientado a columnas debido a su creciente popularidad.

El modelado de datos de un sistema como Cassandra dista del modelado tradicional de las bases de datos relacionales. Cassandra por ejemplo utiliza como unidad básica las Columns cuyo equivalente seria el Campo en el modelo relacional o como unidad de almacenamiento de las Columns utiliza las ColumnFamily como tablas etc..

Para realizar este generador de código se utilizan una serie de técnicas de transformación entre modelos conocidas como "Desarrollo Dirigido por Modelos" (MDD). MDD se puede definir como un enfoque de la Ingeniería del software y de la Ingeniería dirigida por modelos (MDE) que utiliza el modelo para crear un producto. ¿Y que es un modelo?. Un modelo se puede entender como la descripción o representación de un sistema en un lenguaje bien definido. Para entender lo que representa un modelo dentro de MDE hay que saber previamente lo que es un metamodelo. Un metamodelo es un modelo usado para especificar un lenguaje, básicamente describe las características del lenguaje. Por lo tanto un modelo se puede entender como la instancia de un metamodelo. Estos conceptos son ampliados en siguientes secciones.

El resultado de la utilización de MDD es traducido en reducción de costes debido a que el recurso humano requerido es menor, un aumento de la productividad y reutilización de componentes además se puede aumentar el nivel de abstracción a la hora de realizar el diseño de un software.

En resumen la utilización de modelos UML respecto a modelos escritos en Cassandra a la hora de especificar una base de datos no relacional proporciona una abstracción para aquellos usuarios que no estén muy familiarizados con el modelado de bases de datos no relacionales. La utilización de modelos diseñados en UML proporciona ventajas ya que UML es un lenguaje de modelado bien conocido por toda la comunidad. Además la automatización de estos procesos nos permite crear software más rápido, más fiable y de mayor calidad lo que nos lleva a mantener buenas prácticas. Este trabajo pretende contribuir a satisfacer las carencias y virtudes citadas, proporcionando una herramienta que bajo las bases de un proceso de transformación dirigido por modelos transforma y genera keyspaces para sistemas NoSQL orientado a columnas. Esperamos que esto permita a los equipos de desarrollo ahorrar esfuerzos y, por lo tanto, reducir costes.

En las siguientes secciones se desarrollan los siguientes aspectos: El apartado 1.2 expande información sobre la Ingeniería dirigida por modelos y el Desarrollo Dirigido por Modelos, este apartado es vital para entender todo lo relacionado con la memoria presente. El apartado 1.3 presenta la motivación y objetivos del proyecto. Finalmente el apartado 1.4 describe la estructura que tendrá el documento presente.

1.2. Antecedentes: Ingeniería Dirigida por Modelos y Desarrollo Dirigido por modelos

Según [6] la Ingeniería Dirigida por Modelos (MDE) puede ser definida como la *"técnica que hace uso, de forma sistemática y reiterada, de modelos como elementos primordiales a largo de todo el proceso de desarrollo. MDE trabaja con modelos como entradas al proceso y produce modelos como salidas del mismo"*. El concepto de Desarrollo Dirigido por Modelos (MDD) es como se puede observar en la Figura 1.1, etiqueta 1). un subconjunto de la Ingeniería Dirigida por Modelos (MDE). A diferencia de MDD,[7] MDE va más allá de las actividades de desarrollo de puros y abarca otras tareas basadas en el proceso de modelado por ejemplo, aplicar ingeniería inversa a un modelo.

Tanto MDD como MDE aportan varias ventajas respecto a métodos de desarrollo tradicionales, podemos encontrar las siguientes ventajas [8], [9]:

1. Tiempo de desarrollo menor.
2. Reutilización de componentes en distintos sistemas.




Figura 1.1: Capas del modelado de lenguajes

3. Alto nivel de abstracción para escribir aplicaciones y artefactos de software a través de la arquitectura de niveles del meta-modelado y las capas de modelado de MDD. Este beneficio favorece diseñar una aplicación partiendo de lo mas general a lo más concreto, es decir, son independientes de la tecnología.
4. Un menor número de líneas de código escritas, ya que los niveles de abstracción que aporta MDD a través de los modelos y metamodelos diseñados fomentan el reúso del código y de los modelos.
5. Si se centran los esfuerzos en el generador de código se puede mejorar la calidad del software, además reducimos la cantidad de errores así como el tiempo incurrido en pruebas e incurrimos en buenas practicas de desarrollo.

Una vez entendidos los conceptos anteriores y los beneficios que nos proporciona este enfoque de desarrollo se presentan los conceptos básicos que nos ayudaran a comprender como funciona MDD.

El enfoque MDD parte del metamodelo [10], un metamodelo es la representación del lenguaje que se desea implementar en sintaxis abstracta. Un lenguaje de modelado está formado de sintaxis y semántica. La sintaxis son el conjunto de normas o reglas de escritura del lenguaje. La semántica refleja el significado de la sintaxis. La definición de la sintaxis abstracta es el primer paso en el proceso de diseño de un lenguaje. Especifica la forma del metamodelo. Clases y relaciones de dominio son los principales elementos que forman parte de un metamodelo. Los metamodelos son considerados instancias de estos lenguajes de modelado. Un ejemplo de metamodelo es la definición de UML [11]. En UML por ejemplo elementos como las clases, paquetes o atributos se pueden usar dentro del propio UML.

La definición de la sintaxis concreta es el siguiente paso, este paso consiste en la representación de los elementos bien definidos en la sintaxis abstracta.

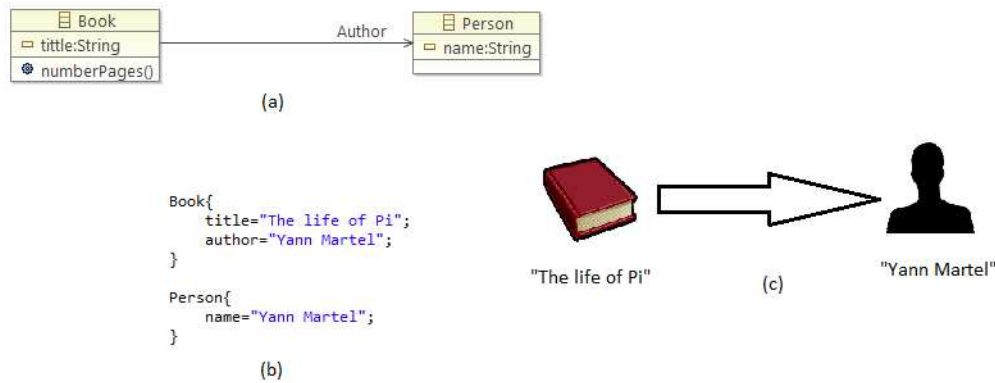


Figura 1.2: (a) Metamodelo, (b) Sintaxis concreta, (c) Sintaxis grafica

Véase la creación de un modelo. Un modelo es la representación concreta de los elementos descritos en la sintaxis abstracta o metamodelo. Por lo tanto un modelo siempre posee las propiedades y cumple las restricciones de su metamodelo. En la (Figura 1.2, etiqueta 2) se pueden observar representaciones de los elementos descritos.

Según [10] estos son los pasos que hay que realizar para la creación de un nuevo lenguaje de modelado:

1. En primer lugar hay que establecer cuál va a ser la sintaxis de nuestro lenguaje de modelado. Para ello hay que crear un metamodelo el cual como se comentaba anteriormente establece cuales son las reglas que han de seguir los modelos. El metamodelo ha de ser construido utilizando un lenguaje de metamodelado, el lenguaje de modelado utilizado en el presente proyecto es ECore [8]. Además de ECore hay otros lenguajes de modelado como puede ser MOF [9].
2. El siguiente paso consiste en la definición de la sintaxis concreta de nuestro lenguaje de modelado. La creación de un modelo bien definido a partir del metamodelo creado en el paso anterior.
3. La definición de la semántica del lenguaje de modelado es el último paso, por ejemplo crear un generador que transforme los elementos del modelo en elementos de un lenguaje distinto bien definido.

La herramienta con la que se va a trabajar es EMF un plugin de eclipse que nos permite crear y trabajar con lenguajes de modelado. MDE proporciona las transformaciones de modelos como principal herramienta para trabajar con modelos en el proceso de desarrollo software. Existen dos tipos de transformaciones:

1. *Model to model (M2M)*. Dado un modelo de entrada esta transformación produce otro modelo como salida. Este tipo de transformación

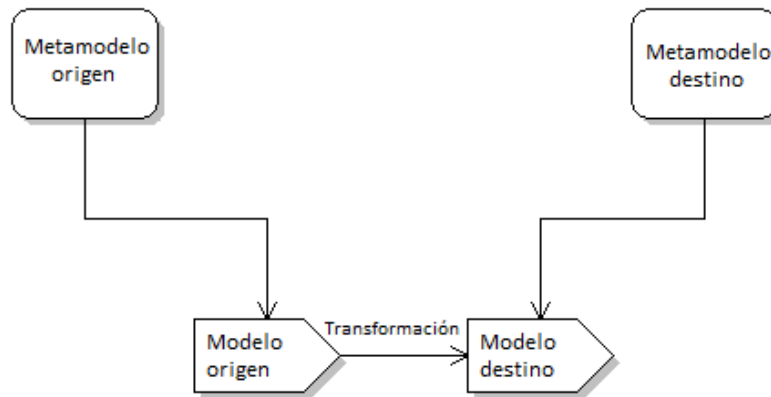


Figura 1.3: Proceso de transformación de un modelo

se puede utilizar de varias formas, la primera transformar un modelo dándole propiedades que no posee el original. La segunda es la que se utilizara en el presente proyecto, dado un modelo origen definido en UML realizar una transformación a un modelo destino definido en Cassandra (Figura 1.3, etiqueta 3). Esta información es ampliada en el siguiente capítulo.

2. *Model to text (M2T)*. Es la ultima transformación que se realiza en la etapa de desarrollo para generar el código de la aplicación. Estas transformaciones no generan un modelo de salida sino una representación textual del modelo que se desea transformar. Se puede utilizar para generar por ejemplo una representación del modelo transformado en formato HTML.

Para explicar todo este proceso se presenta un sencillo ejemplo donde se explican cómo se utilizan brevemente las técnicas de desarrollo dirigido por modelos, Model to Model (M2M) y Model to Text (M2T). Para aplicar M2M nos harán falta dos metamodelos (uno origen y uno destino) y para aplicar M2T se ha diseñado un sencillo generador de código HTML.

La (Figura 1.4, etiqueta 4) muestra la representación de la sintaxis abstracta o metamodelo del lenguaje. El metamodelo consiste en un sencillo grafo el cual está compuesto de un número indefinido de nodos los cuales están conectados entre sí mediante aristas. Estos nodos como se ve en la imagen tienen un atributo de tipo "Tcolor" por lo que un Nodo puede ser de color rojo o de color azul. Por lo tanto un modelo bien definido de este metamodelo será un modelo que contenga un grafo con un numero cualquiera de Nodos conectados dos a dos entre sí mediante aristas.

A continuación se presenta otro metamodelo como se ve en la (Figura 1.5, etiqueta 5). Este metamodelo consiste en la representación de una red de




Figura 1.4: Metamodelo de un grafo

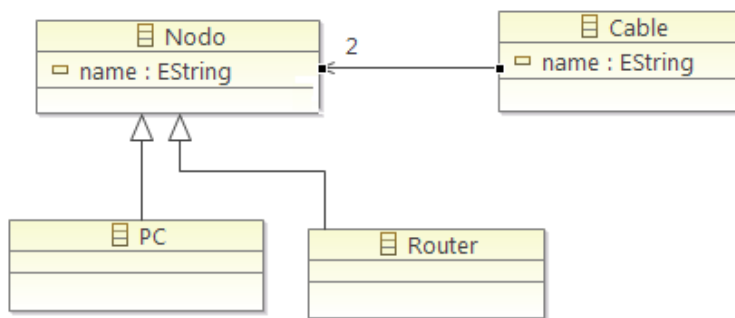


Figura 1.5: Metamodelo de una red

computadores que está compuesta de PC's y Routers estos análogamente al anterior metamodelo están conectados indistintamente entre sí mediante cables. Tanto los nodos como los cables tiene un atributo de tipo "String" para definir el nombre.

Nuestro objetivo es la transformación de un modelo de tipo Grafo a un modelo de tipo Red, dependiendo del color del Nodo, el Nodo será transformado en un PC o en un Router (Rojo-PC, Azul-Router) para realizar esta transformación se utilizan técnicas M2M.

Una vez obtenido el modelo de tipo Red deseamos representar textualmente el modelo generado para ello utilizamos técnicas M2T. En este caso la representación del modelo es realizada en formato HTML. La representación del código generado utilizando un modelo de tipo grafo y aplicando la transformación entre modelos es el que se puede observar en la (Figura 1.6, etiqueta 6).

El proceso que se ha seguido es explicado más detalladamente en capítulos posteriores, tanto las técnicas de transformación de modelos como la

Conexiones

A1	PC1	Router1
A2	PC2	PC3
A3	Router2	PC4

Figura 1.6: Resultado transformación HTML

realización del generador de código así como la creación de los modelos.

1.3. Motivación y Objetivos

Como hemos visto a lo largo de la introducción el enfoque que proporciona el Desarrollo Dirigido por Modelos así como la Ingeniería Dirigida por Modelos nos proporciona múltiples ventajas respecto al desarrollo tradicional por lo que la utilización de este enfoque es apropiada para la realización del generador de código así como para las transformaciones entre modelos.

El objetivo de este proyecto de fin de carrera es la implementación de un generador de código que transforme un modelo UML en su correspondiente código ejecutable en Cassandra. Para ello, previa implementación del generador de código habrá que transformar el modelo UML a un modelo escrito en Cassandra. Por lo tanto necesitaremos desarrollar un metamodelo que describa el lenguaje de Cassandra y el metamodelo de UML. Dicho generador y dicha transformación se desarrollaran utilizando el enfoque y las técnicas que proporcionan el Desarrollo Dirigido por Modelos. Esta implementación será realizada con el framework que proporciona eclipse de modelado llamado EMF.

Como resultado del proyecto se genera un código escrito en el lenguaje de Cassandra (CQL-Cassandra Query Language) que puede ser ejecutado en cualquier herramienta que soporte dicho lenguaje.

1.4. Estructura del Documento

Tras este capítulo de introducción, la presente memoria del Proyecto Fin de Carrera se estructura tal y como se describe a continuación: El Capítulo 2 describe en términos generales todos los conceptos y tecnologías que son necesarios para comprender el contenido de esta memoria conceptos tales como Cassandra o EMF por ejemplo. El Capítulo 3 describe como se ha realizado la transformación de modelos así como la metodología de transformación de modelos (M2M). El Capítulo 4 describe como se ha realizado el generador de

código así como las técnicas y tecnologías utilizadas. Finalmente el Capítulo 5 presenta mis conclusiones tras la realización del proyecto así como posibles mejoras de la herramienta. (Puede cambiar).

Capítulo 2

Antecedentes y Planificación

Este capítulo describe las tecnologías y técnicas utilizadas en el desarrollo del presente Proyecto de Fin de Carrera. La primera sección está dedicada a introducir el caso de estudio del PFC presentado, el cual consiste en la realización de un generador de código Cassandra que transforma modelos UML a modelos escritos en Cassandra. La siguiente sección está dedicada a describir en qué consiste EMF el lenguaje utilizado para desarrollar lenguajes de modelado. A continuación se describe la herramienta Epsilon que se ha utilizado para desarrollar el generador de código. La siguiente sección está dedicada a explicar de manera breve algunos conceptos de Cassandra. Finalmente se expone la planificación que ha seguido el proyecto para su realización, desde formación hasta desarrollo.

Índice

2.1. Caso de estudio: Generador de código CQL-Cassandra	11
2.2. EMF	11
2.3. Epsilon	12
2.4. Cassandra	15
2.5. Planificación	17
2.6. Sumario	19

2.1. Caso de estudio: Generador de código CQL-Cassandra

2.2. EMF

Eclipse Modeling Framework (EMF) [2.2] es un framework de modelado que nos proporciona la base para la elaboración de lenguajes de modelado. Para la creación de metamodelos EMF [2.3] utiliza dos modelos de metadatos: Ecore y Genmodel. Ecore contiene la información sobre las clases que

se han definido. Genmodel contiene información adicional para la generación del código, por ejemplo la ruta y la información del archivo. Utilizando EMF se pueden crear metamodelos de forma gráfica muy similar a los diagramas de clases en UML. EMF permite crear un metamodelo a través de diferentes medios, por ejemplo, XMI, anotaciones Java, XML o UML. EMF proporciona un framework para almacenar la información del modelo.

Un ejemplo sencillo de la utilidad de EMF es el siguiente: Imaginemos que deseamos construir una aplicación para manipular mensajes escritos en XML. El primer paso que daríamos sería empezar definiendo el schema del mensaje sin embargo con EMF se puede trabajar ignorando este nivel. Con EMF podemos crear plugins que generen por ejemplo un diagrama de clases UML a partir de este mensaje XML o directamente generar el código Java que implemente las clases del mensaje XML.

2.3. Epsilon

Epsilon es una familia de lenguajes y herramientas para el desarrollo de software dirigido por modelos, entre estas podemos encontrar: la transformación de modelos, validación de modelos, generación de código entre otras funcionalidades. Epsilon es distribuido a través de la plataforma de modelado de lenguajes de Eclipse.

Epsilon proporciona multitud de lenguajes y herramientas para trabajar con modelos. Los lenguajes utilizados en este proyecto son EOL (Epsilon Object Language), ETL (Epsilon Transformation Language) y EGL (Epsilon Generation Language) también ha sido utilizado EUnit como herramienta para validar el código escrito por el generador de código Cassandra-CQL. Estos lenguajes y herramientas son descritos a continuación.

2.3.1. Epsilon Object Language

[2.1] Epsilon Object Language (EOL) es un lenguaje de programación imperativo utilizado para crear, consultar y modificar los modelos EMF. Según [2.1] EOL se puede considerar el lenguaje como una mezcla de Javascript y OCL, que combina lo mejor de ambos lenguajes. Como tal, proporciona todas las características habituales imperativas que se encuentran en Javascript (por ejemplo, la secuencia de la declaración, las variables, bucles for y while, etc) y todas las características interesantes de OCL como las operaciones sobre las colecciones (por ejemplo `Sequence1..5.select (x — x.3)`).

Para entender mejor el funcionamiento de EOL se expone el siguiente ejemplo. Se ha definido el metamodelo mostrado en la figura 2.1 el cual consiste en la representación de una casa y las personas que viven en ella. Las personas tienen un nombre y un atributo booleano que representa si una




Figura 2.1: Ejemplo metamodelo casa

```

-----
for (person in Person.all){
    if (person.alive == true) {
        person.name.println();
    }
}

//Podemos realizar lo mismo de la siguiente manera:

Person.all.select(r|r.alive==true).name.println();
-----

```

Figura 2.2: Ejemplo código EOL

persona está viva o no. Existe una relación de agregación para reflejar que la casa contiene personas.

Una vez creado el metamodelo podemos crear un modelo como una instancia de ese metamodelo. Un ejemplo de cómo funciona EOL puede ser el siguiente: deseamos saber que personas habitan en la casa y están vivas. La sintaxis correspondiente sería la siguiente (figura 2.2).

Como vemos la sintaxis es muy similar a cualquier lenguaje orientado a objetos, podemos manipular y consultar los objetos del modelo, sin embargo EOL no nos permite la definición de clases.

```

pre {
    "Running ETL".println();
    var Red : new Red!Red;
    Red.nameRed="Red1";
    var iPC:new Integer=1;
    var iRouter:new Integer=1;
}

rule Arista2Cable
transform a : Grafo!Arista
to r : Red!Cable {
    r.nameCable = a.nombreArista;
    if (a.parent.isDefined()) {
        r.parent=Red;
        for (nodoArista in a.children) {
            if(nodoArista.color=TColor#R){
                var PC : new Red!PC;
                PC.nameNodo="PC"+iPC;
                r.children.add(PC);
                iPC=iPC+1;
            }
        }
    }
    else{
        var Router : new Red!Router;
        Router.nameNodo="Router"+iRouter;
        r.children.add(Router);
        iRouter=iRouter+1;
    }
}
}

```

Figura 2.3: Ejemplo código ETL

2.3.2. Epsilon Transformation Language

[2.1] Epsilon Transformation Language (ETL) es un lenguaje de transformación modelo a modelo basado en reglas (Model to Model-M2M). ETL proporciona las características estándar de un lenguaje de transformación, también nos permite manipular los modelos de entrada y salida así como su código fuente. ETL tiene su propia sintaxis sin embargo utiliza el lenguaje EOL como base.

Recordando el ejemplo de la Red de computadores y el Grafo detallado en el capítulo anterior (sección 1.2). Deseamos realizar la transformación de un modelo de tipo grafo a un modelo de tipo red para ello utilizaremos ETL. En primer lugar necesitamos el modelo del grafo para poder realizar la transformación a un modelo de tipo Red. La figura 2.3 muestra el código que realiza el proceso de transformación de un Grafo a una Red.

La sección de código inicial define algunas variables previa ejecución de

las reglas. En ella se inicializan variables que se utilizaran posteriormente. En este código encontramos solo una regla. Esta regla transforma aristas del grafo a cables de la red. La primera instrucción copia el nombre de la arista al cable. A continuación la primera condicional cuestiona si esa arista tiene un padre definido en caso afirmativo asigna el cable a la red. A continuación por cada nodo se crea o bien un PC o un router dependiendo del color del nodo que se esté analizando (rojo-PC, azul-Router). En siguiente lugar se asigna el nodo creado al cable correspondiente y finalmente se añade a la red. Este proceso se repite por cada arista del grafo. Una vez ejecutado este código dado un modelo de entrada de tipo Grafo obtenemos un modelo de tipo Red que cumple las reglas definidas en el metamodelo.

2.3.3. Epsilon Generation Language

[2.1] [2.4] Epsilon Generation Language (EGL) es un lenguaje utilizado para la generación de código basado en la transformación de modelos (Model to Text-M2T). EGL puede ser utilizado para transformar los modelos en varios tipos de lenguajes, por ejemplo código ejecutable Java, código HTML o incluso aplicaciones completas que comprenden el código en varios lenguajes (por ejemplo, HTML, Javascript y CSS).

Cada plantilla de EGL contiene varias secciones. Cada sección puede ser estática o bien dinámica. Una sección estática contiene texto que aparecerá en la salida generada por la plantilla. Una sección dinámica comienza con la secuencia '[%' y termina con la secuencia '%]'. La sección dinámica contiene el lenguaje (EOL, Epsilon Object Language).

La figura 2.4 muestra como se realiza la generación de código HTML utilizando para ello el modelo generado de una red a partir de un grafo (ver sección anterior).

2.4. Cassandra

<http://www.nosql-database.org/> [chalmers] Desde que nació SQL en el año 1974, SQL ha sido el modelo de base de datos relacionales utilizado por excelencia. En los últimos años ha surgido otra vertiente denominada NoSQL la cual surge por la necesidad de manejo de grandes volúmenes de información no estructurada, distribuida con la mayor rapidez posible. NoSQL es usado en plataformas como Facebook o Twitter. Podemos encontrar varios tipos de bases de datos no relacionales; Bases de datos documentales, bases de datos clave-valor, orientadas a grafos y mas tipos.

Las principales características de NoSQL que difieren de SQL son:

1. NoSQL no garantiza las propiedades ACID (atomicidad, coherencia, aislamiento y durabilidad).

```

-----
[%
    var red: Red := Red.allInstances().at(0);
%]

<html>
    <head>
        <title> Red </title>
    </head>
    <body>
        <h1>Conexiones</h1>
        <table border="1">
            <col style="width: 200px" />
            <col style="width: 100px" span="3" />
            [% for (conexiones in red.conexiones){%]
            <tr>
                <th scope="row">[%=conexiones.nameCable%]</th>
                [% for (nodos in conexiones.children){%]
                <td>[%=nodos.nameNodo%]</td>
                [% }%]
            </tr>
            [% }%]
        </table>
    </body>
</html>
-----

```

Figura 2.4: Ejemplo código EGL

2. No utiliza SQL como lenguaje de consultas. Algunas bases de datos no relacionales utilizan SQL como lenguaje de apoyo sin embargo la mayoría utilizan su propio lenguaje de consultas como por ejemplo Cassandra que utiliza CQL.
3. No está permitido el uso de joins ya que al manejar grandes volúmenes de información una consulta con un join puede llegar a sobrecargar el sistema.
4. Escalan horizontalmente y trabajan de manera distribuida por lo que la información puede estar en distintas maquinas y el añadir nodos mejora el rendimiento.
5. Resuelven problemas de altos volúmenes de información

En este proyecto de fin de carrera se utiliza Cassandra, Cassandra es una distribución de bases de datos no relaciones (NoSQL). Dentro del mundo de las bases de datos no relaciones Cassandra pertenece a la familia de bases de datos denominada “clave-valor”. Las bases de datos clave-valor son aquellas que asocian los valores a una determinada clave esto permite la recuperación

y escritura de información de forma muy rápida y eficiente. Cassandra reúne las tecnologías de sistemas distribuidos de Amazon Dynamo y el modelo de datos BigTable de Google. Al igual que Dynamo, Cassandra es consistente. Como BigTable, Cassandra proporciona un modelo de datos basado en ColumnFamily siendo considerado el sistema basado en clave-valor más popular.

Las bases de datos basadas en Cassandra son soluciones utilizadas cuando es necesaria escalabilidad y alta disponibilidad sin comprometer el rendimiento. Escalabilidad lineal y tolerancia a fallos o infraestructura en la nube lo convierten en la plataforma perfecta para datos de misión crítica. Cassandra proporciona gran estabilidad en cuanto a la replicación de datos a través de múltiples datacenters, consiguiendo una menor latencia para sus usuarios y la tranquilidad de que no existan pérdidas de datos ante caídas. Cassandra utiliza un lenguaje llamado CQL (Cassandra Query Language) con una sintaxis muy similar a SQL aunque con menos funcionalidades.

Fue diseñado por Avinash Lakshman (uno de los creadores de Amazon's Dynamo) y Prashant Malik (Ingeniero de Facebook). Cassandra está en producción para Facebook sin embargo aun está en fase de desarrollo.

A continuación se explican algunos términos que hay que tener en cuenta cuando se trabaja con Cassandra. En Cassandra un KeySpace es el equivalente a una base de datos en los sistemas de bases de datos relacionales. El conocido término de tabla en las bases de datos relacionales tiene su equivalente en Cassandra llamado Column Family. Por lo tanto un KeySpace puede contener varias Column Families y una Column Family a su vez contiene varias columnas. Una columna es la unidad de almacenamiento básica, está formada de tres campos: Nombre, un valor y un timestamp. El nombre y el valor se almacena como una matriz de bytes sin procesar y pueden ser de cualquier tamaño. Un ejemplo: Nombre de la columna ÜusernameNombre de usuario ÑIgnacioTimestamp Ñ123456789La sintaxis del lenguaje CQL es muy similar a SQL, CQL contiene sintaxis ya conocida de SQL como INSERT, DELETE, UPDATE, INSERT, ... Un ejemplo de código CQL ejecutable es el siguiente (Figura 2.5)

2.5. Planificación

Como se ha comentado en el presente documento, el objetivo de este proyecto de fin de carrera es la implementación de un generador de código Cassandra a partir de modelos UML. El proceso de desarrollo así como el de aprendizaje que se ha seguido para la realización del proyecto queda reflejado en la figura [figuraProceso].

La primera tarea como es evidente consistió en adquirir los conocimientos necesarios para el desarrollo del proyecto, en primer lugar todo lo relacionado con el proceso de modelado de un lenguaje y transformación de lenguajes

```
DROP KEYSPACE twitter;

CREATE KEYSPACE twitter
WITH replication = {'class':'SimpleStrategy', 'replication_factor':2};

USE twitter;

CREATE TABLE Tweet(
    UUID text,
    usernameTw text,
    body text,
    PRIMARY KEY(UUID)
);

CREATE TABLE User(
    username text,
    password text,
    followers set<text>,
    followings set<text>,
    tweets_written list<text>,
    PRIMARY KEY(username)
);
```

Figura 2.5: Ejemplo código CQL

[kleppe]. También fueron necesarios conocimientos sobre la Ingeniería y el Desarrollo Dirigido por Modelos, también sintaxis y arquitectura de Cassandra.

A continuación se comenzó a trabajar con la herramienta Epsilon, sus lenguajes EOL, EGL, ETL y EUnit como herramienta para las pruebas de los modelos y código generados. Así como con lenguaje para la definición de lenguajes de modelado EMF.

Para conocer cómo funcionaban estos lenguajes se desarrollaron una serie de casos prácticos para familiarizarse con los métodos de transformación así como con la herramienta y creación de casos de prueba.

Una vez conocido estos conceptos se estudiaron las reglas de transformación de un modelo UML a un modelo Cassandra, estas reglas fueron propuestas por [pabloCassandra].

Tras estas tareas de adquisición de conocimientos se empezó a trabajar en el generador de código Cassandra empezando por la transformación de modelos UML a modelos Cassandra. Una vez finalizada la transformación se comenzó a trabajar en el generador de código Cassandra. Tras realizar dicha tarea se realizaron una serie de casos de prueba para verificar si el resultado del generador de código era el esperado utilizando la herramienta EUnit.

Una vez desarrollado el generador de código se realizaron distintos casos de prueba sobre Cassandra para probar el correcto funcionamiento del

generador de código.

Pruebas integración

2.6. Sumario

Durante este capítulo se han descrito los conceptos necesarios para lograr comprender el ámbito y el alcance de este proyecto, se ha descrito el caso de estudio planteado en el proyecto también se ha hablado sobre tecnologías implicadas en el desarrollo del generador de código, Cassandra y su arquitectura, Epsilon los lenguajes utilizados y herramientas utilizadas. El siguiente capítulo describe

Capítulo 3

Model to text

Este capítulo describe el primer paso del proceso de transformación de acuerdo al proceso de desarrollo dirigido por modelos. El principal objetivo de esta fase es la transformación de un modelo definido en UML a un modelo en Cassandra. La primera fase consiste en la definición de un metamodelo que defina el modelado en Cassandra. En segundo lugar debemos definir las reglas de transformación para convertir un modelo UML a un modelo en Cassandra utilizando para ello el lenguaje ETL.

Índice

3.1. Introducción	21
3.2. Metamodelo Cassandra	21
3.3. Transformación de Modelo UML a Cassandra	23
3.4. Caso de estudio	26
3.5. Pruebas	26
3.6. Sumario	26

3.1. Introducción

3.2. Metamodelo Cassandra

Como habíamos descrito en el capítulo anterior la base del proceso de transformación entre modelos parte del metamodelo. El metamodelo utilizado de UML en este proyecto es el que nos proporciona Epsilon, dicho metamodelo sigue el estándar de UML 2.0. Sin embargo nos hace falta un metamodelo que defina el lenguaje de Cassandra. Dicho metamodelo fue proporcionado por Pablo Sánchez Barreiro. El metamodelo sufrió algunos cambios respecto al inicial debido a exigencias del proyecto. El metamodelo de Cassandra es el que se ve en la figura Figura 3.1.

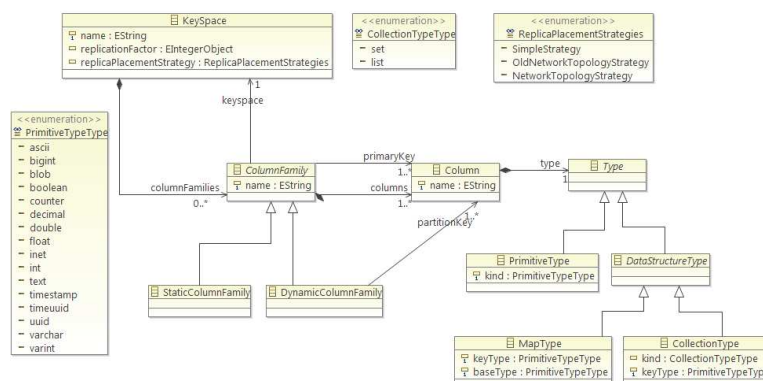


Figura 3.1: Metamodelo Cassandra

El eje central del metamodelo es el `KeySpace`, el `KeySpace` es el equivalente a la base de datos en el modelo relacional, la clase del metamodelo `KeySpace` cuenta con los atributos: nombre utilizado para denominar el `KeySpace`, `[cassandra] replicationFactor` número de servidores de Cassandra de los que se debe guardar un registro u obtener una respuesta al recuperar algún registro y `replicaPlacementStrategy` que es la estrategia de replicación que se va a tomar, estrategias tenemos tres tipos: `SimpleStrategy`: Esta estrategia es la estrategia de replicación utilizada por defecto al crear un `KeySpace` utilizando Cassandra. Es utilizada para clústeres de data centers simples. `NetworkTopologyStrategy`: Utilizada cuando se tiene (o se va a tener) el clúster desplegado a través de múltiples data centers. Esta estrategia especifica cuántas réplicas se desean en cada data center. `OldNetworkTopologyStrategy`: Se utiliza para proporcionar retro compatibilidad con instalaciones Cassandra antiguas.

A continuación tenemos la clase `ColumnFamily` equivalente a las tablas en el modelo relacional, dentro de las CF encontramos dos tipos: las `StaticColumnFamily` y las `DynamicColumnFamily`. Recordamos que la CF estática es el equivalente a la tabla en el modelo relacional, sin embargo la CF dinámica es utilizada para la recuperación de datos eficiente, algo similar a las vistas del modelo relacional. En CQL el orden de definición de las claves importa, en la primera columna se define la `Partition Key` esta tiene la propiedad de que todas las filas que comparten la misma `Partition Key` se almacenan en el mismo nodo físico. Además, la inserción, actualización o eliminación de filas que comparten la `Partition Key` para una CF determinada se realizan de forma atómica. Es posible tener una `Partition Key` compuesta, es decir, una `Partition Key` formada por varias columnas, en CQL esto se define utilizando paréntesis para delimitar el conjunto de partición. Dentro de las `ColumnFamily` encontramos `Columns` estos son los valores que se almacenan en las `Column Families` las cuales tienen el nombre como atributo y un tipo de dato. Dentro de los tipos encontramos dos

clases, `PrimitiveType` y `DataStructureType`, el primero define los tipos primitivos, por ejemplo entero, texto, uuid, etc.. `DataStructureType` define las colecciones, estas pueden ser de dos tipos `MapType` o bien `CollectionType`, ambas tiene un atributo llamado `KeyType` para definir el tipo primitivo que las caracteriza. `MapType` cuenta con un atributo llamado `baseType` de tipo primitivo que define el segundo tipo de dato del mapa. Dentro de `CollectionType` encontramos un atributo llamado `kind` que define el tipo de colección que vamos a utilizar esta puede ser o bien tipo set o tipo list. Más adelante se explica que características reúne cada colección y mapa y cuando se utilizan.

3.3. Transformación de Modelo UML a Cassandra

Una vez definido el metamodelo de Cassandra utilizamos ETL para establecer las reglas de transformación entre UML y Cassandra CQL. Recordamos que el lenguaje ETL es el lenguaje que utiliza Epsilon para la transformación entre modelos basado en reglas. A continuación se presenta una explicación de las reglas junto con el código correspondiente. Las reglas de transformación son definidas en [docPablo]. A continuación se detalla cómo se han implementado dichas reglas en el lenguaje de definición de reglas de transformación ETL. Como vemos estas dos reglas transforman una clase definida en UML a una `Column Family` estática de Cassandra (el equivalente a una tabla en el sistema de bases de datos relacionales). La primera regla es definida para las clases que tengan un atributo clave definido, para ello se utiliza la propiedad `isID` la cual define que ese atributo identifica a la clase de forma única. La segunda para las clases sin atributo clave definido. El proceso de transformación es similar en ambas reglas, en primer lugar se asigna la `Column Family` al `KeySpace` que le corresponde, se copia el nombre de la clase a la `Column Family` y se añade al conjunto de `Column Families` del `KeySpace`. Sin embargo en la segunda regla se crea un atributo que va a ser la clave de esa `Column Family` ya que no tiene, dicha clave tendrá de nombre el nombre de la clase el distintivo `_ID` será de tipo uuid. Dichas reglas están definidas en el punto 5.3 del documento. La siguiente regla define como se realiza la transformación de un atributo del modelo UML a una columna del modelo Cassandra. Para ello en primer lugar se define una guarda para que la transformación se haga solo de los atributos de clase y no los atributos de relación. A continuación se realiza un filtro para evitar la adición de columnas que no pertenezcan al modelo de datos. Una vez hecho esto hay que diferenciar dos tipos de atributos, aquellos cuya tamaño sea igual a 1 y aquellos cuyo tamaño sea mayor de 1. En cuanto a los atributos de tamaño igual a 1 se realiza la transformación del atributo copiando su tipo de dato. Respecto a los atributos de tamaño mayor de 1 se aplica la siguiente regla: Aquellos atributos que sean únicos y no ordenados

son definidos como tipo "set" de Cassandra. En caso contrario se definen como tipo list. A continuación en ambos casos se realiza la transformación correspondiente del tipo de dato UML a Cassandra se copia el nombre y se añade la columna ya transformada a la Column Family correspondiente. Finalmente en caso de que el atributo sea clave de la clase se añade a la Column Family como Primary Key. El código correspondiente a esta regla es el siguiente figura 3.2

La siguiente regla define como se realiza la transformación de los atributos de las asociaciones entre clases UML. En primer lugar hay que diferenciar como se tratan las asociaciones, aquellas asociaciones cuyo extremo tenga una cardinalidad igual a uno y aquellas con una cardinalidad mayor de uno. Para los extremos con cardinalidad igual a uno se crea una columna que será añadida en la Column Family del otro extremo de la relación, esta columna nueva es una copia de la Primary Key de la Column Family fuente, el nombre de la nueva columna es la composición del nombre de la Column Family y del nombre de la Primary Key, el tipo de la nueva columna es el mismo del de la Primary Key de la Column Family fuente. Esto se comprende mejor con el ejemplo propuesto más adelante.

Para los extremos con cardinalidad mayor de uno, se crea una Column Family dinámica. En la primera columna se define la Partition Key. El resto de columnas de la Primary Key se utilizan para definir las llamadas Clustering Columns, estas se utilizan para la recuperación de filas de manera eficiente. La transformación utilizada para este tipo de Column Family es la siguiente: Esta CF dinámica está compuesta de dos columnas, la primera columna y segunda columna juegan el papel de Partition Key de la CF, la primera columna se construye de la misma manera que el caso anterior, se copia el nombre y el tipo de la Primary Key del extremo de la asociación fuente. La segunda columna de la misma manera toma los datos (nombre y tipo de la PK) del otro extremo de la asociación. El rol de Cluster Key lo desempeña la primera columna creada. El nombre de la CF será la concatenación del nombre de las CF de ambos extremos (primero fuente, segundo extremo fin de la asociación). En resumen la definición de la Primary Key es la siguiente:

1. Partition Key: Primera columna (fuente de la asociación), segunda columna (extremo de la asociación).
2. Clustering Columns: Primera columna (fuente de la asociación).

En cuanto a la transformación de variables de tipo primitivo se define la siguiente operación de esta manera podemos convertir un tipo primitivo UML a su equivalente en Cassandra. Dicha regla está definida en el punto 5.4 del documento. Como se explicaba en el anterior capítulo él para ello nos hará falta realizar la creación de un modelo UML de acuerdo a las principales reglas de este lenguaje de modelado. En primer lugar se ha

```

-----
//5.5 Attribute with primitive type transformation
rule Attribute2Column
transform attribute : UML!Property
to column : nosql!Column {
    guard: (("+"attribute.qualifiedName).contains("Data::") and attribute.type.isKindOf(UML!PrimitiveType))

    //filtramos para evitar añadir columnas ajenas al modelo de datos
    for(cfamilY in kspace.columnFamilies){

        if(attribute.qualifiedName=="Data::"+cfamilY.name+"::"+attribute.name){

            //5.5 Attribute with primitive type transformation->Attributes with upper bound = 1
            if(attribute.upper=1){
                //transformacion del atributo en una columna basica
                var type : new nosql!PrimitiveType;
                type.kind=umlType2modelType(attribute.type.name);
                column.type=type;
            }
            //5.5 Attribute with primitive type transformation->Attributes with upper bound > 1
            else if(attribute.upper<>0){
                //transformacion del atributo en un set o list
                var ctype : new nosql!CollectionType;

                if(attribute.isUnique and not attribute.isOrdered)//set
                    ctype.kind=nosql!CollectionTypeType#set;
                else//list
                    ctype.kind=nosql!CollectionTypeType#list;

                ctype.keyType=umlType2modelType(attribute.type.name);
                column.type=ctype;
            }

            column.name=attribute.name;
            cfamilY.columns.add(column);

            //5.1 Assignment of keys to classes
            if(attribute.isID)
                cfamilY.primaryKey.add(column);

        }
    }
}
-----

```

Figura 3.2: Regla de transformación XX

utilizado la herramienta EMF descrita anteriormente para la creación del modelo, a continuación se ha exportado este modelo UML a la herramienta de transformación de modelos Epsilon.

3.4. Caso de estudio

3.5. Pruebas

3.6. Sumario

Durante este capítulo se ha descrito